



**Universidade de Brasília
Departamento de Estatística**

**Análises Multivariadas Aplicadas à Avaliação do Desempenho dos Jogadores
do Campeonato Brasileiro da Série A de 2024**

Henrique Silva Nince

Relatório apresentado para o Departamento de Estatística da Universidade de Brasília como parte dos requisitos necessários para obtenção do grau de Bacharel em Estatística.

**Brasília
2025**

Henrique Silva Nince

**Análises Multivariadas Aplicadas à Avaliação do Desempenho dos Jogadores
do Campeonato Brasileiro da Série A de 2024**

Orientador(a): Prof. Gladston Luiz da Silva

Relatório apresentado para o Departamento de Estatística da Universidade de Brasília como parte dos requisitos necessários para obtenção do grau de Bacharel em Estatística.

**Brasília
2025**

Agradecimentos

- Agradeço primeiramente aos meus pais, Nívia Silva e Sidney Nince, por todas as condições, oportunidades e valores que me permitiram chegar até aqui;
- Ao meu avô Uvermar Nince, por sempre me incentivar a dar o meu melhor e acreditar no meu potencial;
- À minha mulher, Ana Clara Valério, meu maior apoio durante toda essa trajetória. Obrigado por caminhar ao meu lado, me fortalecer nos momentos difíceis e celebrar comigo cada conquista;
- Agradeço também ao Matheus Martinez, amigo que se tornou meu mentor e que me orientou desde a escolha do curso até minhas oportunidades profissionais;
- Por fim, agradeço ao meu orientador Prof. Gladston Luiz e aos meus colegas Tiago Sampaio e Francisco Ferreira, que contribuíram diretamente para tornar este trabalho possível.

Resumo

Este estudo propõe um modelo estatístico para avaliar o desempenho dos jogadores do Campeonato Brasileiro de 2024. Foram utilizadas técnicas de Análise Fatorial para reduzir a dimensionalidade das métricas avançadas da plataforma *FBref*, permitindo identificar fatores latentes representativos das contribuições ofensivas, criativas, defensivas e táticas dos atletas. A partir desses fatores, calculou-se um Score Final, sintetizando o desempenho global de cada jogador.

A Clusterização via *K-means* possibilitou identificar grupos de atletas com perfis de performance semelhantes, reforçando a capacidade discriminativa do modelo. Além disso, a validação externa foi realizada comparando os resultados com as Seleções do Campeonato divulgadas pelo GE e pela ESPN, demonstrando alta coerência entre o indicador construído e as avaliações especializadas.

O modelo mostrou-se eficaz para distinguir diferentes níveis de desempenho e fornecer uma visão estruturada da atuação dos atletas ao longo da temporada, oferecendo uma ferramenta objetiva para análise comparativa entre jogadores.

Palavras-chave: Análise Fatorial; métricas avançadas; score; Clusterização; desempenho; seleção; Campeonato Brasileiro de 2024.

Lista de Tabelas

1	Medidas de Ajuste do Modelo Fatorial Unifatorial para Goleiros	40
2	Top 5 Goleiros.	41
3	Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Goleiros.	43
4	Medidas de Ajuste do Modelo Fatorial com 4 Fatores para Zagueiros	47
5	Top 5 Zagueiros.	48
6	Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Zagueiros.	51
7	Resultado do teste de Dunn para comparações múltiplas entre os clusters dos Zagueiros.	51
8	Medidas de Ajuste do Modelo Fatorial com 3 Fatores para Laterais	56
9	Top 5 Laterais Direita.	57
10	Top 5 Laterais Esquerda.	57
11	Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Laterais.	60
12	Medidas de Ajuste do Modelo Fatorial com 6 fatores para Volantes	64
13	Top 5 Volantes.	65
14	Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Volantes.	68
15	Resultado do teste de Dunn para comparações entre os clusters dos Volantes.	68
16	Medidas de Ajuste do Modelo Fatorial com 2 fatores para Meias	72
17	Top 5 Meias.	73
18	Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Meias.	75
19	Resultado do teste de Dunn para comparações entre os clusters dos Meias.	75
20	Medidas de Ajuste do Modelo Fatorial com 4 fatores para Pontas	79
21	Top 5 Pontas Direita.	80

22	Top 5 Pontas Esquerda.	80
23	Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Pontas.	83
24	Resultado do teste de Dunn para comparações entre os clusters dos Pontas.	83
25	Medidas de Ajuste do Modelo Fatorial com 4 fatores para Atacantes	87
26	Top 5 Atacantes.	88
27	Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Atacantes.	90
28	Resultado do teste de Dunn para comparações entre os clusters dos Atacantes.	91
29	Cargas Fatoriais (F1), Comunalidades (h^2) e Unicidade (u^2) para Goleiros.	98
30	Cargas Fatoriais (F1–F4), Comunalidades (h^2) e Unicidade (u^2) para Zagueiros.	99
31	Cargas Fatoriais (F1–F3), Comunalidades (h^2) e Unicidade (u^2) para Laterais.	100
32	Cargas Fatoriais (F1–F6), Comunalidades (h^2) e Unicidade (u^2) para Volantes.	101
33	Cargas Fatoriais (F1–F2), Comunalidades (h^2) e Unicidade (u^2) para Meias.	102
34	Cargas Fatoriais (F1–F4), Comunalidades (h^2) e Unicidade (u^2) para Pontas.	103
35	Cargas Fatoriais (F1–F4), Comunalidades (h^2) e Unicidade (u^2) para Atacantes.	104

Lista de Figuras

1	Exemplo ilustrativo de um <i>boxplot</i> . Fonte: adaptado de <i>Fernanda F. Peres</i> (fernandafperes.com.br).	11
2	Exemplo ilustrativo de um <i>Scree Plot</i> . Fonte: adaptado de <i>The Julia Group Blog</i> (thejuliagroup.com).	18
3	Exemplo ilustrativo de uma Análise Paralela. Fonte: adaptado de <i>RPubs – Exploratory Factor Analysis</i> (rpubs.com).	19
4	Exemplo ilustrativo do <i>Elbow Method</i> . Fonte: adaptado de <i>Built In</i> (builtin.com).	26
5	Exemplo ilustrativo do <i>Silhouette Method</i> . Fonte: adaptado de <i>Introdução ao Machine Learning — Grupo DataAt (2023)</i> (dataat.github.io).	27
6	Exemplo ilustrativo do <i>Silhouette Method</i> . Fonte: adaptado de <i>LinkedIn Pulse — Diego Parra (2023)</i> (linkedin.com).	27
7	Mapa de calor da matriz de correlações para Goleiros.	36
8	Mapa de calor da matriz de correlações para Jogadores de Linha.	37
9	<i>Scree plot</i> para Goleiros.	39
10	Análise Paralela para Goleiros.	39
11	Método do Cotovelo para definição do número de clusters dos Goleiros. . .	41
12	Método da Silhueta para definição do número de clusters dos Goleiros. . .	42
13	Gráfico de Silhueta para $k = 2$ na clusterização dos Goleiros.	43
14	Distribuição do Score Final dos Goleiros por cluster.	44
15	<i>Scree plot</i> para Zagueiros.	46
16	Análise Paralela para Zagueiros.	46
17	Método do Cotovelo para definição do número de clusters dos Zagueiros. .	49
18	Método da Silhueta para definição do número de clusters dos Zagueiros. . .	50
19	Gráfico de Silhueta para $k = 3$ na clusterização dos Zagueiros.	51
20	Distribuição do Score Final dos Zagueiros por cluster.	52
21	<i>Scree plot</i> para Laterais.	55

22	Análise Paralela para Laterais.	55
23	Método do Cotovelo para definição do número de clusters dos Laterais. . .	58
24	Método da Silhueta para definição do número de clusters dos Laterais. . .	59
25	Gráfico de Silhueta para $k = 2$ na clusterização dos Laterais.	60
26	Distribuição do Score Final dos Laterais por cluster.	61
27	<i>Scree plot</i> para Volantes.	63
28	Análise Paralela para Volantes.	63
29	Método do Cotovelo para definição do número de clusters dos Volantes. . .	66
30	Método da Silhueta para definição do número de clusters dos Volantes. . .	67
31	Gráfico de Silhueta para $k = 3$ na clusterização dos Volantes.	68
32	Distribuição do Score Final dos Volantes por cluster.	69
33	<i>Scree plot</i> para Meias.	71
34	Análise Paralela para Meias.	71
35	Método do Cotovelo para definição do número de clusters dos Meias. . . .	74
36	Método da Silhueta para definição do número de clusters dos Meias. . . .	74
37	Gráfico de Silhueta para $k = 3$ na clusterização dos Meias.	75
38	Distribuição do Score Final dos Meias por cluster.	76
39	<i>Scree plot</i> para Pontas.	78
40	Análise Paralela para Pontas.	78
41	Método do Cotovelo para definição do número de clusters dos Pontas. . . .	81
42	Método da Silhueta para definição do número de clusters dos Pontas. . . .	81
43	Gráfico de Silhueta para $k = 3$ na clusterização dos Pontas.	82
44	Distribuição do Score Final dos Pontas por cluster.	83
45	<i>Scree plot</i> para Atacantes.	86
46	Análise Paralela para Atacantes.	86
47	Método do Cotovelo para definição do número de clusters dos Atacantes. .	89
48	Método da Silhueta para definição do número de clusters dos Atacantes. .	89
49	Gráfico de Silhueta para $k = 3$ na clusterização dos Atacantes.	90

50	Distribuição do Score Final dos Atacantes por cluster.	91
51	Comparação entre a Seleção do Campeonato baseada no Score Final (esquerda), a Seleção do GE (centro) e a Seleção da ESPN (direita).	93

Sumário

1 Introdução	8
2 Referencial Teórico	10
2.1 Boxplot	10
2.2 Correlação	11
2.3 Testes de Hipóteses	12
2.3.1 Teste de Normalidade de Shapiro-Wilk	12
2.3.2 Teste de Kruskal-Wallis	13
2.3.3 Teste de Comparações Múltiplas de Dunn	14
2.4 Análise Fatorial	15
2.4.1 Índice de Adequação da Amostra (KMO)	16
2.4.2 Definição do Número de Fatores	17
2.4.3 Método dos Mínimos Resíduos (MINRES)	19
2.4.4 Rotação dos Fatores	20
2.4.5 Avaliação do Ajuste do Modelo	21
2.4.6 Cálculo dos Scores Fatoriais pelo Método da Regressão	22
2.5 Clusterização pelo Método <i>K-means</i>	24
2.5.1 Definição do Número de Clusters	25
3 Metodologia	28
3.1 Coleta e Tratamento de Dados	28
3.1.1 Conjunto de dados	28
3.1.2 Preparação e Limpeza dos Dados	28
3.2 Análises Estatísticas	31
3.2.1 Análise das Correlações	31
3.2.2 Análise Fatorial	31
3.2.3 Clusterização pelo Método <i>K-means</i>	33
3.3 Validação dos Resultados	35

3.4 Ferramentas e Softwares Utilizados	35
4 Resultados	36
4.1 Análise das Correlações	36
4.1.1 Goleiros	36
4.1.2 Jogadores de Linha	37
4.2 Análise dos Goleiros	38
4.2.1 Preparação e Limpeza dos Dados	38
4.2.2 Análise Fatorial	38
4.2.3 Clusterização pelo Método <i>K-means</i>	41
4.2.4 Validação dos Resultados	44
4.3 Análise dos Zagueiros	45
4.3.1 Preparação e Limpeza dos Dados	45
4.3.2 Análise Fatorial	45
4.3.3 Clusterização pelo Método <i>K-means</i>	49
4.3.4 Validação dos Resultados	53
4.4 Análise dos Laterais	54
4.4.1 Preparação e Limpeza dos Dados	54
4.4.2 Análise Fatorial	54
4.4.3 Clusterização pelo Método <i>K-means</i>	58
4.4.4 Validação dos Resultados	61
4.5 Análise dos Volantes	62
4.5.1 Preparação e Limpeza dos Dados	62
4.5.2 Análise Fatorial	62
4.5.3 Clusterização pelo Método <i>K-means</i>	65
4.5.4 Validação dos Resultados	69
4.6 Análise dos Meias	70
4.6.1 Preparação e Limpeza dos Dados	70
4.6.2 Análise Fatorial	70

4.6.3	Clusterização pelo Método <i>K-means</i>	73
4.6.4	Validação dos Resultados	76
4.7	Análise dos Pontas	77
4.7.1	Preparação e Limpeza dos Dados	77
4.7.2	Análise Fatorial	77
4.7.3	Clusterização pelo Método <i>K-means</i>	80
4.7.4	Validação dos Resultados	84
4.8	Análise dos Atacantes	85
4.8.1	Preparação e Limpeza dos Dados	85
4.8.2	Análise Fatorial	85
4.8.3	Clusterização pelo Método <i>K-means</i>	88
4.8.4	Validação dos Resultados	92
4.9	Seleção do Campeonato	93
5	Conclusão	94
6	Limitações e Trabalhos Futuros	95
	Referências	97
	Apêndice	98
A	Cargas Fatoriais, Comunalidades e Unicidade para Goleiros	98
B	Cargas Fatoriais, Comunalidades e Unicidade para Zagueiros	99
C	Cargas Fatoriais, Comunalidades e Unicidade para Laterais	100
D	Cargas Fatoriais, Comunalidades e Unicidade para Volantes	101
E	Cargas Fatoriais, Comunalidades e Unicidade para Meias	102
F	Cargas Fatoriais, Comunalidades e Unicidade para Pontas	103
G	Cargas Fatoriais, Comunalidades e Unicidade para Atacantes	104
	Anexo	105
	Anexo A: Variáveis dos Jogadores de Linha	105
	Anexo B: Variáveis dos Goleiros	110

1 Introdução

A análise estatística tem desempenhado um papel cada vez mais relevante no esporte mundial, transformando profundamente a forma como o desempenho de atletas e equipes é avaliado. Essa transformação ganhou notoriedade a partir do beisebol norte-americano, quando Billy Beane e Paul DePodesta, dirigentes do Oakland Athletics, desafiaram os métodos tradicionais de avaliação de jogadores. Em vez de se apoiarem em percepções subjetivas, passaram a utilizar métricas quantitativas como porcentagem de rebatidas e controle de *strike*, introduzindo um novo paradigma de análise de desempenho (LEWIS, 2004). Esse movimento, conhecido como a “revolução do *Moneyball*”, marcou o início de uma era em que dados e modelos estatísticos se tornaram ferramentas estratégicas para decisões esportivas.

Inspirados por esse avanço, clubes e ligas europeias passaram a investir, nas últimas décadas, em departamentos especializados em *data science* e modelagem preditiva. De acordo com reportagem publicada por Khashab (2025), a LaLiga espanhola lidera uma revolução tecnológica no futebol europeu, incorporando inteligência artificial, análises preditivas e sistemas de rastreamento em tempo real para otimizar o desempenho tático e físico dos atletas. O uso de indicadores como *expected goals* (xG), mapas de calor e métricas de movimentação tornou-se rotina em comissões técnicas e departamentos de desempenho, consolidando o papel da estatística como um elemento central na estratégia esportiva contemporânea.

No Brasil, esse movimento começa a ganhar força. Segundo Ribas (2025), clubes como Flamengo, Palmeiras e Athletico-PR têm investido em equipes de análise de dados e em plataformas especializadas para mensurar o desempenho técnico e físico dos atletas. A reportagem destaca que a análise estatística, antes restrita às comissões técnicas, passou a influenciar também a gestão de elenco, a prospecção de talentos e o planejamento estratégico. Essa integração entre estatística e futebol representa um passo importante rumo à profissionalização das decisões esportivas no país, reduzindo a subjetividade e promovendo maior eficiência na gestão dos clubes.

A aplicação de técnicas estatísticas e de aprendizado de máquina oferece novas perspectivas para compreender o jogo e quantificar o desempenho dos jogadores. Modelos preditivos, análises multivariadas e indicadores de eficiência permitem identificar atletas promissores, detectar padrões táticos e avaliar contribuições individuais com base em critérios objetivos. Ao adotar essas metodologias, o futebol brasileiro pode se alinhar às melhores práticas observadas nas principais ligas do mundo, fortalecendo uma cultura

esportiva orientada por dados.

Dessa forma, este trabalho teve como objetivo demonstrar a importância das análises estatísticas no contexto do futebol brasileiro, com ênfase na quantificação de desempenho dos jogadores e equipes. Para isso, foram empregadas técnicas estatísticas multivariadas, como a Análise Fatorial e a Clusterização *K-means*, que permitem identificar padrões de desempenho não perceptíveis por métodos tradicionais de avaliação, frequentemente influenciados por julgamentos subjetivos. A partir dessas abordagens, foi possível classificar atletas de maneira quantitativa e propor uma Seleção do Campeonato baseada em critérios estatísticos, reproduzíveis e sustentados por rigor metodológico.

2 Referencial Teórico

2.1 Boxplot

O diagrama de caixa, ou *boxplot*, é uma representação gráfica que resume a distribuição de um conjunto de dados numéricos por meio de seus principais valores descritivos. Segundo Bussab e Morettin (2003), o boxplot é uma ferramenta útil da análise exploratória de dados, pois permite visualizar a tendência central, a dispersão, a simetria e a presença de possíveis valores discrepantes (*outliers*).

O boxplot é construído a partir dos quartis da distribuição:

- Q_1 : primeiro quartil (25% dos dados abaixo deste valor);
- Q_2 : segundo quartil ou mediana (50% dos dados abaixo deste valor);
- Q_3 : terceiro quartil (75% dos dados abaixo deste valor).

A caixa representa o intervalo interquartil (IQR), calculado como $IQR = Q_3 - Q_1$, que contém os 50% centrais das observações. As linhas que se estendem a partir da caixa, chamadas de “bigodes”, indicam os limites inferior e superior dos dados não discrepantes, definidos como

$$\text{Limite Inferior} = Q_1 - 1,5 \times IQR \quad \text{e} \quad \text{Limite Superior} = Q_3 + 1,5 \times IQR.$$

Observações que ultrapassam esses limites são classificadas como *outliers* e geralmente são representadas por pontos individuais. O boxplot é uma forma eficiente de detectar assimetrias e comparar distribuições entre grupos ou categorias, sendo amplamente utilizado em análises exploratórias e em etapas preliminares de modelagem estatística (BUSSAB; MORETTIN, 2003).




Figura 1: Exemplo ilustrativo de um *boxplot*. Fonte: adaptado de *Fernanda F. Peres* (fernandafperes.com.br).

2.2 Correlação

A correlação é uma medida estatística que expressa o grau de associação entre duas variáveis quantitativas. O coeficiente de correlação linear de Pearson é utilizado para quantificar a intensidade e a direção da relação linear entre duas variáveis numéricas (BUSSAB; MORETTIN, 2003).

Matematicamente, o coeficiente de correlação (r) é definido como

$$r = \frac{\text{Cov}(X, Y)}{s_X s_Y},$$

em que $\text{Cov}(X, Y)$ representa a covariância entre as variáveis X e Y , e s_X e s_Y são os respectivos desvios-padrão. O valor de r varia entre -1 e 1 , sendo que:

- $r = 1$ indica correlação linear positiva perfeita;
- $r = -1$ indica correlação linear negativa perfeita;
- $r = 0$ indica ausência de correlação linear.

De acordo com Bussab e Morettin (2003), é importante destacar que uma correlação próxima de zero não implica necessariamente ausência de relação entre as variáveis,

mas apenas ausência de relação *linear*. Além disso, o coeficiente de correlação não deve ser interpretado como evidência de causalidade, mas sim como uma medida de associação.

2.3 Testes de Hipóteses

Os testes de hipóteses são procedimentos estatísticos utilizados para verificar se uma suposição sobre um parâmetro populacional é compatível com as evidências fornecidas por uma amostra. O processo de teste de hipóteses consiste em formular duas hipóteses contraditórias: a hipótese nula (H_0) e a hipótese alternativa (H_1) (BUSSAB; MORETTIN, 2003).

A hipótese nula representa uma afirmação de igualdade ou de ausência de efeito, sendo a hipótese que se pretende testar inicialmente. Já a hipótese alternativa reflete a existência de diferença ou efeito, sendo aceita quando as evidências amostrais são suficientemente fortes para rejeitar H_0 .

De acordo com Bussab e Morettin (2003), o procedimento de teste segue as seguintes etapas principais:

1. Formulação das hipóteses H_0 e H_1 ;
2. Escolha do nível de significância (α), que representa a probabilidade máxima de rejeitar H_0 quando ela é verdadeira;
3. Definição da estatística de teste apropriada;
4. Determinação da região crítica ou valor crítico;
5. Cálculo da estatística de teste a partir dos dados amostrais;
6. Tomada de decisão: rejeitar ou não rejeitar H_0 .

2.3.1 Teste de Normalidade de Shapiro-Wilk

O teste de Shapiro-Wilk é um procedimento estatístico utilizado para verificar se uma amostra provém de uma população com distribuição normal (SHAPIRO; WILK, 1965). A verificação da normalidade dos dados é uma etapa essencial em análises multivariadas, uma vez que diversos métodos inferenciais, como a análise fatorial e a regressão múltipla, pressupõem que as variáveis sigam uma distribuição normal.

A normalidade pode ser avaliada por meio de métodos gráficos, como histogramas e gráficos Q-Q, ou por testes formais, sendo o de Shapiro-Wilk um dos mais recomendados para amostras pequenas e médias. O teste baseia-se na correlação entre os valores observados e os valores esperados sob uma distribuição normal teórica. Valores próximos indicam conformidade com a normalidade (SHAPIRO; WILK, 1965).

A estatística do teste de Shapiro-Wilk (W) é dada por

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)}\right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

na qual $x_{(i)}$ representa as observações ordenadas, $\bar{x}$ é a média amostral, e a_i são coeficientes obtidos a partir dos valores esperados e da covariância das ordens sob a hipótese de normalidade.

O valor de W varia entre 0 e 1. Valores próximos de 1 indicam que a amostra segue a distribuição normal, enquanto valores baixos sugerem desvios da normalidade. O p -valor associado ao teste é utilizado para tomada de decisão: se $p < \alpha$, rejeita-se a hipótese nula de normalidade.

2.3.2 Teste de Kruskal–Wallis

O teste de Kruskal–Wallis é um procedimento estatístico não paramétrico utilizado para comparar grupos independentes, avaliando se suas distribuições apresentam diferenças significativas (KRUSKAL; WALLIS, 1952). Este teste é uma alternativa à análise de variância (ANOVA) tradicional quando o pressuposto de normalidade dos dados não é atendido.

Ao contrário dos testes paramétricos, o Kruskal–Wallis não utiliza os valores originais das observações, mas sim suas posições em um ranking conjunto. Todas as observações são ordenadas do menor para o maior valor, e cada uma recebe uma posição (ou posto). A comparação entre os grupos é realizada com base nas somas desses postos.

A estatística de teste (H) é calculada pela seguinte expressão:

$$H = \frac{12}{N(N+1)} \sum_{j=1}^k n_j \bar{R}_j^2 - 3(N+1),$$

em que:

- k é o número de grupos independentes;

- n_j é o tamanho amostral do grupo j ;
- $\bar{R}_j$ é a média dos postos do grupo j ;
- N é o tamanho total da amostra ($N = \sum n_j$).

Sob a hipótese nula de que todas as amostras provêm da mesma população (ou de populações com distribuições idênticas), a estatística H segue aproximadamente uma distribuição qui-quadrado com $k - 1$ graus de liberdade. Valores elevados de H indicam maior evidência contra a hipótese nula.

O teste de Kruskal–Wallis é particularmente útil em situações nas quais os dados não atendem aos pressupostos de homocedasticidade e normalidade, sendo amplamente empregado em estudos empíricos para comparação de medianas entre grupos (KRUSKAL; WALLIS, 1952).

Quando o resultado do teste indica diferença significativa, recomenda-se a aplicação de testes post hoc, como o teste de Dunn, explicado na Seção 2.3.3, para identificar quais grupos diferem entre si.

2.3.3 Teste de Comparações Múltiplas de Dunn

O teste de Dunn, proposto por Dunn (1961), é um procedimento não paramétrico utilizado para realizar comparações múltiplas entre grupos independentes após a rejeição da hipótese nula no teste de Kruskal–Wallis. Seu objetivo é identificar quais pares de grupos apresentam diferenças estatisticamente significativas, controlando o erro do tipo I em testes múltiplos.

O método baseia-se nas diferenças entre as médias dos postos dos grupos, utilizando a distribuição normal padrão como referência para determinar a significância das comparações (DUNN, 1961). A estatística de teste é dada por

$$Z_{ij} = \frac{|\bar{R}_i - \bar{R}_j|}{\sqrt{\frac{N(N+1)}{12} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}},$$

na qual:

- $\bar{R}_i$ e $\bar{R}_j$ são as médias dos postos dos grupos i e j ;
- n_i e n_j são os tamanhos amostrais dos grupos i e j ;
- N é o tamanho total da amostra.

O valor absoluto de Z_{ij} é comparado com o valor crítico da distribuição normal (Z_α), ajustado para múltiplas comparações por meio de correções como o método de Bonferroni. Se $|Z_{ij}| > Z_\alpha$, conclui-se que os grupos i e j diferem significativamente entre si.

O teste de Dunn é especialmente útil em análises em que os dados não atendem aos pressupostos de normalidade e homogeneidade de variâncias, oferecendo uma alternativa robusta às comparações múltiplas pós-ANOVA. Assim, em conjunto com o teste de Kruskal–Wallis, constitui um procedimento completo para identificar diferenças entre medianas de grupos independentes em estudos empíricos.

2.4 Análise Fatorial

A Análise Fatorial é uma técnica estatística multivariada utilizada para identificar a estrutura subjacente de um conjunto de variáveis observadas, agrupando-as em fatores latentes que explicam os padrões de correlação existentes entre elas. O principal objetivo da Análise Fatorial é reduzir a dimensionalidade dos dados, mantendo o máximo possível da variância explicada pelo conjunto original de variáveis (HAIR et al., 2009).

De acordo com Hair et al. (2009), a análise fatorial baseia-se na premissa de que diversas variáveis observadas podem ser expressas como combinações lineares de um número menor de fatores comuns e de fatores específicos. O modelo fatorial pode ser representado da seguinte forma:

$$X_i = a_{i1}F_1 + a_{i2}F_2 + \cdots + a_{im}F_m + U_i,$$

no qual:

- X_i representa a i -ésima variável observada;
- F_j representa o j -ésimo fator comum;
- a_{ij} são as *cargas fatoriais*, que indicam o grau de correlação entre a variável e o fator;
- U_i é o termo de unicidade (ou fator específico), representando a variância não explicada pelos fatores comuns.

O processo de análise fatorial envolve várias etapas:

1. **Verificação da adequação da amostra:** realizada por meio de medidas como o índice KMO (*Kaiser-Meyer-Olkin*), que avalia se a matriz de correlação é apropriada para a análise fatorial;
2. **Extração dos fatores:** tem como objetivo determinar o número inicial de fatores que melhor representam os dados;
3. **Rotação dos fatores:** etapa destinada a facilitar a interpretação dos resultados, redistribuindo a variância explicada entre os fatores. Pode ser ortogonal (como Varimax) ou oblíqua (como Oblimin);
4. **Interpretação dos fatores:** realizada a partir das cargas fatoriais, que expressam a correlação entre cada variável e o fator correspondente. Cargas mais altas indicam maior contribuição da variável para o fator;
5. **Cálculo dos scores fatoriais:** valores que representam o posicionamento de cada observação em relação aos fatores extraídos, permitindo comparações e análises posteriores.

2.4.1 Índice de Adequação da Amostra (KMO)

O índice KMO (*Kaiser-Meyer-Olkin*) é uma medida utilizada para avaliar a adequação dos dados à aplicação da Análise Fatorial. Segundo Hair et al. (2009), o índice de adequação da amostra verifica se as correlações parciais entre as variáveis são suficientemente pequenas, indicando se o padrão de correlações é apropriado para a extração de fatores comuns.

Matematicamente, o índice KMO é definido como

$$KMO = \frac{\sum_{i \neq j} r_{ij}^2}{\sum_{i \neq j} r_{ij}^2 + \sum_{i \neq j} p_{ij}^2},$$

em que:

- r_{ij} representa o coeficiente de correlação simples entre as variáveis i e j ;
- p_{ij} representa o coeficiente de correlação parcial entre as mesmas variáveis, controlando as demais.

Valores do KMO próximos de 1 indicam que os padrões de correlação são compactos e, portanto, adequados para a aplicação da Análise Fatorial. Já valores baixos

indicam que as correlações parciais são elevadas, sugerindo que a análise fatorial pode não ser apropriada.

De acordo com Hair et al. (2009), a interpretação do índice de adequação da amostra pode seguir a seguinte classificação geral:

Valor do índice	Interpretação
0,90 a 1,00	Excelente
0,80 a 0,89	Muito bom
0,70 a 0,79	Bom
0,60 a 0,69	Mediano
0,50 a 0,59	Ruim
Abaixo de 0,50	Inadequado

2.4.2 Definição do Número de Fatores

Uma das etapas mais importantes da Análise Fatorial é a determinação do número adequado de fatores a serem extraídos. A escolha incorreta da quantidade de fatores pode comprometer tanto a interpretação quanto a validade estatística do modelo (HAIR et al., 2009). Diversos critérios podem ser utilizados para essa decisão, destacando-se o critério de autovalores, o gráfico *Scree Plot* e a Análise Paralela.

Critério dos Autovalores (Kaiser)

De acordo com Hair et al. (2009), o critério mais tradicional consiste em reter apenas os fatores com autovalores superiores a 1, conhecido como *critério de Kaiser*. Um autovalor representa a quantidade de variância total explicada por um fator; assim, fatores com autovalores inferiores a 1 explicam menos variância do que uma variável original e, portanto, são descartados. Embora simples e amplamente utilizado, esse critério tende a superestimar o número de fatores, especialmente em amostras pequenas ou quando há muitas variáveis.

Gráfico *Scree Plot*

Outro método recomendado por Hair et al. (2009) é o gráfico de sedimentação, ou *Scree Plot*, que representa graficamente os autovalores em função do número de fatores extraídos. O ponto de inflexão (ou “cotovelo”) do gráfico indica o número ideal de fatores a serem mantidos, aqueles localizados antes da queda acentuada dos autovalores.

Fatores localizados após esse ponto tendem a representar apenas variância aleatória e são geralmente descartados.




Figura 2: Exemplo ilustrativo de um *Scree Plot*. Fonte: adaptado de *The Julia Group Blog* (thejuliagroup.com).

Análise Paralela

A Análise Paralela é considerada um dos métodos mais robustos para a definição do número de fatores. Esse procedimento consiste em comparar os autovalores obtidos na amostra real com os autovalores médios obtidos de várias amostras aleatórias simuladas com o mesmo número de variáveis e observações. Apenas os fatores cujo autovalor real excede o autovalor correspondente da amostra aleatória são retidos (HORN, 1965).




Figura 3: Exemplo ilustrativo de uma Análise Paralela. Fonte: adaptado de *RPubs – Exploratory Factor Analysis* (rpubs.com).

A Análise Paralela tem como vantagem reduzir a subjetividade inerente ao *Scree Plot* e ao critério de Kaiser, oferecendo uma decisão mais consistente, especialmente em amostras grandes ou quando os fatores possuem variâncias similares.

2.4.3 Método dos Mínimos Resíduos (MINRES)

O método dos Mínimos Resíduos (*Minimum Residuals* – MINRES) é uma técnica de extração utilizada na Análise Fatorial que busca minimizar a diferença entre a matriz de correlação observada e a matriz de correlação reproduzida pelo modelo fatorial. Esse método é especialmente útil quando o pressuposto de normalidade multivariada não é atendido, apresentando boa estabilidade em amostras de tamanho moderado ou pequeno (HARMAN, 1976).

De forma geral, a Análise Fatorial assume que as variáveis observadas podem ser representadas como combinações lineares de fatores comuns e fatores específicos, conforme o modelo estrutural

$$\mathbf{R} = \mathbf{A}\mathbf{A}' + \mathbf{U},$$

em que:

- $\mathbf{R}$ é a matriz de correlação observada entre as variáveis;
- $\mathbf{A}$ é a matriz de cargas fatoriais;
- $\mathbf{U}$ é uma matriz diagonal contendo as variâncias específicas (unicidades).

O método MINRES, descrito formalmente por Harman (1976), estima as cargas fatoriais $\mathbf{A}$ de modo a minimizar a soma dos quadrados dos resíduos entre as correlações observadas e as correlações reproduzidas pelo modelo, ou seja:

$$\min_{\mathbf{A}} \sum_{i < j} (r_{ij} - \hat{r}_{ij})^2,$$

em que r_{ij} representa a correlação empírica entre as variáveis i e j , e $\hat{r}_{ij}$ é a correlação reproduzida a partir do modelo fatorial. O objetivo é encontrar uma solução em que a estrutura fatorial reproduza de forma mais precisa possível o padrão de correlações observado, minimizando o erro global de ajuste.

O método dos Mínimos Resíduos apresenta vantagens importantes em relação a métodos como a Máxima Verossimilhança (ML), por não depender de suposições rígidas sobre a distribuição dos dados e por evitar operações matriciais complexas que podem gerar instabilidade numérica. Além disso, ele tende a produzir resultados semelhantes aos métodos mais sofisticados quando a estrutura dos dados é bem definida (HARMAN, 1976).

2.4.4 Rotação dos Fatores

A rotação fatorial é uma etapa essencial na Análise Fatorial, pois tem como objetivo simplificar e tornar mais clara a estrutura dos fatores extraídos, facilitando sua interpretação. Segundo Hair et al. (2009), a rotação redistribui a variância explicada entre os fatores, buscando uma solução mais facilmente interpretável sem alterar o poder explicativo total do modelo.

As rotações podem ser classificadas em dois grandes grupos: **ortogonais** e **oblíquas**. As rotações ortogonais, como a Varimax, mantêm os fatores não correlacionados entre si. Já as rotações oblíquas, como a Oblimin, permitem correlação entre os fatores, o que frequentemente reflete melhor a realidade empírica dos dados (HAIR et al., 2009).

Rotação Oblimin

De acordo com Hair et al. (2009), a **rotação Oblimin** é um dos métodos oblíquos mais utilizados, especialmente em contextos nos quais se espera que os fatores possuam alguma relação conceitual ou empírica. Isso ocorre porque, em muitos fenômenos estudados, as dimensões latentes não são totalmente independentes, por exemplo, aspectos cognitivos e emocionais em psicologia, ou atributos técnicos e táticos no desempenho esportivo.

O método Oblimin procura atingir uma estrutura fatorial simples, assim como as rotações ortogonais, mas sem impor a restrição de independência entre os fatores. Dessa forma, permite que a matriz de correlação dos fatores apresente covariâncias diferentes de zero, resultando em uma representação mais realista das relações entre dimensões latentes.

A escolha entre uma rotação ortogonal (como Varimax) e uma oblíqua (como Oblimin) deve ser guiada pelo objetivo da pesquisa e pela natureza teórica dos dados (HAIR et al., 2009). Quando há evidências ou pressupostos de que os fatores podem estar correlacionados, recomenda-se a utilização de rotações oblíquas, uma vez que estas produzem resultados mais consistentes com a estrutura subjacente do fenômeno analisado.

2.4.5 Avaliação do Ajuste do Modelo

A avaliação do ajuste do modelo fatorial pode ser realizada por meio de diferentes índices, que permitem analisar, de forma complementar, o grau de adequação entre a matriz de correlações observada e aquela reproduzida pelo modelo estimado.

RMSEA (*Root Mean Square Error of Approximation*)

O RMSEA avalia o erro médio de aproximação do modelo à população, penalizando modelos excessivamente complexos. Valores menores indicam melhor ajuste, sendo geralmente aceitos valores inferiores a 0,08 como indicativos de ajuste razoável e inferiores a 0,05 como ajuste muito bom. Trata-se de um índice sensível à parcimônia, favorecendo modelos mais simples quando adequados aos dados.

RMSR (*Root Mean Square of Residuals*)

O RMSR representa a raiz quadrada da média dos resíduos entre as correlações observadas e as correlações reproduzidas pelo modelo. Valores mais baixos indicam menor discrepância entre as matrizes, refletindo melhor ajuste global. De modo geral, valores próximos ou inferiores a 0,08 são considerados aceitáveis, dependendo do contexto e da complexidade do modelo.

TLI (*Tucker-Lewis Index*)

O TLI é um índice de ajuste incremental que compara o modelo estimado a um modelo nulo, levando em consideração a complexidade do modelo. Valores mais próximos

de 1 indicam melhor ajuste, sendo comumente adotado como critério valores superiores a 0,90 para ajuste adequado e superiores a 0,95 para ajuste excelente.

Fit (off-diagonal)

O índice de ajuste off-diagonal avalia a capacidade do modelo em reproduzir as correlações fora da diagonal principal da matriz de correlações, isto é, as associações entre variáveis distintas. Valores mais elevados indicam melhor ajuste do modelo, sendo geralmente considerados aceitáveis valores a partir de 0,80 e indicativos de ajuste muito bom valores superiores a 0,90. Esse índice é particularmente útil em análises fatoriais exploratórias, pois permite avaliar diretamente a qualidade com que a estrutura fatorial estimada representa as inter-relações entre os itens.

Variância Explicada

A variância explicada corresponde à proporção da variabilidade total dos dados que é capturada pelos fatores extraídos. Valores mais elevados indicam maior poder explicativo do modelo fatorial. Em análises exploratórias, não há um ponto de corte rígido, mas espera-se que o conjunto de fatores explique uma parcela substancial da variância total, compatível com a complexidade do construto analisado e com a literatura da área.

2.4.6 Cálculo dos Scores Fatoriais pelo Método da Regressão

Após a extração e rotação dos fatores, é possível estimar os scores fatoriais, que representam o posicionamento de cada observação em relação aos fatores extraídos. Esses scores permitem que os fatores, originalmente latentes e não observáveis, sejam quantificados para cada indivíduo ou unidade amostral (HAIR et al., 2009).

Segundo Hair et al. (2009), o cálculo dos scores fatoriais pode ser realizado por diferentes métodos, sendo os mais comuns o método da regressão, o método de Bartlett e o método de Anderson–Rubin. No presente estudo, optou-se pelo **método da regressão** (*regression method*), o mais amplamente utilizado em análises exploratórias, por oferecer estimativas eficientes e facilmente interpretáveis.

De acordo com Johnson e Wichern (2007), a formulação geral do modelo fatorial pode ser representada por

$$\mathbf{x} = \mathbf{\Lambda f} + \boldsymbol{\epsilon},$$

em que:

- $\mathbf{x}$ é o vetor das variáveis observadas (padronizadas);
- $\mathbf{\Lambda}$ é a matriz de cargas fatoriais;
- $\mathbf{f}$ é o vetor dos fatores comuns;
- ϵ representa o vetor de erros específicos.

Com base nesse modelo, os scores fatoriais estimados ($\hat{\mathbf{f}}$) podem ser obtidos por meio de uma combinação linear das variáveis padronizadas, ponderadas por um conjunto de pesos $\mathbf{W}$:

$$\hat{\mathbf{f}} = \mathbf{W}'\mathbf{x}.$$

O método da regressão estima os pesos $\mathbf{W}$ de modo a minimizar a soma dos quadrados dos resíduos entre os scores fatoriais verdadeiros ($\mathbf{f}$) e os estimados ($\hat{\mathbf{f}}$), assumindo que as variáveis observadas e os fatores estão correlacionados linearmente. Conforme Mardia, Kent e Bibby (1980), a solução ótima para $\mathbf{W}$ é derivada da relação entre as matrizes de cargas fatoriais, a matriz de covariância dos erros específicos e a matriz de correlação total, sendo expressa como

$$\mathbf{W} = \mathbf{\Psi}^{-1}\mathbf{\Lambda} (\mathbf{I} + \mathbf{\Lambda}'\mathbf{\Psi}^{-1}\mathbf{\Lambda})^{-1},$$

na qual $\mathbf{\Psi}$ é a matriz diagonal das variâncias específicas e $\mathbf{I}$ é a matriz identidade. Essa expressão garante que os scores fatoriais sejam combinações lineares ponderadas das variáveis originais, maximizando a correlação entre os fatores estimados e os verdadeiros.

De acordo com Hair et al. (2009), embora diferentes métodos possam produzir scores numericamente distintos, o método da regressão é amplamente recomendado por gerar estimativas altamente correlacionadas com os fatores teóricos, mantendo coerência entre os resultados e a estrutura fatorial identificada. Além disso, o método permite que os scores sejam utilizados em análises subsequentes, como regressões múltiplas, agrupamentos e comparações entre grupos.

2.5 Clusterização pelo Método *K-means*

A Análise de Agrupamentos (*Cluster Analysis*) é uma técnica estatística multivariada utilizada para identificar grupos homogêneos dentro de um conjunto de observações, de modo que os elementos de um mesmo grupo apresentem características semelhantes entre si e diferentes dos elementos de outros grupos. O objetivo central da Clusterização é classificar objetos ou indivíduos com base em um conjunto de variáveis, sem o uso de informações prévias sobre a estrutura dos grupos, o que caracteriza o método como uma técnica não supervisionada (HAIR et al., 2009).

Entre os métodos de agrupamento, o **K-means** é um dos mais amplamente utilizados devido à sua simplicidade, eficiência computacional e boa performance em grandes bases de dados. De acordo com Hair et al. (2009), o método *K-means* é um procedimento não hierárquico que busca particionar o conjunto de observações em k grupos mutuamente exclusivos, de forma que a variabilidade interna de cada grupo seja minimizada e a variabilidade entre grupos seja maximizada. O algoritmo baseia-se na minimização da soma dos quadrados das distâncias entre as observações e os centróides de seus respectivos grupos.

Matematicamente, a função objetivo do algoritmo pode ser expressa como

$$J = \sum_{j=1}^k \sum_{i=1}^{n_j} \|\mathbf{x}_i^{(j)} - \boldsymbol{\mu}_j\|^2,$$

em que:

- k é o número de clusters definidos pelo pesquisador;
- $\mathbf{x}_i^{(j)}$ representa o vetor de características da i -ésima observação do grupo j ;
- $\boldsymbol{\mu}_j$ é o vetor médio (centróide) do grupo j ;
- $\|\mathbf{x}_i^{(j)} - \boldsymbol{\mu}_j\|^2$ é a distância euclidiana quadrática entre a observação e o centróide.

O procedimento do algoritmo *K-means* segue um processo iterativo: (1) selecionam-se aleatoriamente k centróides iniciais; (2) cada observação é atribuída ao cluster cujo centróide é o mais próximo; (3) os centróides são recalculados com base nas novas atribuições; (4) o processo é repetido até que as mudanças na atribuição das observações se tornem mínimas ou inexistentes (JOHNSON; WICHERN, 2007).

Conforme Hair et al. (2009), a Análise de Agrupamentos requer a padronização prévia das variáveis quando estas se encontram em escalas diferentes, a fim de evitar

que variáveis com maior amplitude influenciem de forma desproporcional a formação dos clusters. O método também é sensível à escolha inicial dos centróides e à presença de valores extremos, sendo recomendável a análise de estabilidade e a realização de múltiplas execuções do algoritmo para garantir a robustez dos resultados.

2.5.1 Definição do Número de Clusters

A definição do número ideal de agrupamentos é uma etapa essencial na análise de clusters, pois influencia diretamente a interpretabilidade e a validade estatística dos resultados. Segundo Hair et al. (2009), o número de grupos deve equilibrar a homogeneidade interna e a heterogeneidade entre clusters, evitando tanto a subquanto a supersegmentação dos dados. Diversos critérios podem ser empregados para essa decisão, entre os quais se destacam o método do cotovelo (*Elbow Method*) e o método da silhueta (*Silhouette Method*), amplamente utilizados e implementados em ferramentas computacionais modernas, como o pacote `NbClust` do *software* R (CHARRAD et al., 2014).

Método *Elbow*

O Método do Cotovelo baseia-se na análise da variabilidade interna dos grupos conforme o número de clusters aumenta. O procedimento consiste em calcular a *soma total dos quadrados das distâncias intragrupos* (*Within-Cluster Sum of Squares* – WSS) para diferentes valores de k . À medida que o número de clusters cresce, o WSS tende a diminuir, uma vez que os grupos tornam-se mais homogêneos. Entretanto, a taxa de redução do WSS não é constante: após certo ponto, o ganho de explicação adicional é marginal. O valor de k correspondente a essa mudança de inclinação, o “cotovelo” da curva, é interpretado como o número ideal de agrupamentos (HAIR et al., 2009).

Graficamente, o método é representado por uma curva decrescente entre o número de clusters e o WSS, onde o ponto de inflexão marca o equilíbrio entre simplicidade e capacidade explicativa do modelo. De acordo com Hair et al. (2009), o método do cotovelo fornece uma avaliação empírica e intuitiva da estrutura natural dos dados, sendo recomendado como um primeiro critério para definição do número de grupos.




Figura 4: Exemplo ilustrativo do *Elbow Method*. Fonte: adaptado de *Built In* (builtin.com).

Método *Silhouette*

O Método da Silhueta, conforme Charrad et al. (2014), é baseado na avaliação simultânea da coesão e da separação dos grupos formados. Para cada observação i , calcula-se o coeficiente de silhueta $s(i)$, definido por

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

em que:

- $a(i)$ é a distância média entre a observação i e todas as demais observações do mesmo cluster;
- $b(i)$ é a menor distância média entre i e as observações pertencentes a outros clusters.

O coeficiente $s(i)$ varia entre -1 e 1: valores próximos de 1 indicam que a observação está bem alocada em seu grupo, valores próximos de 0 sugerem sobreposição entre clusters e valores negativos indicam possível má classificação. O índice global de silhueta é obtido pela média de $s(i)$ sobre todas as observações, sendo o número de clusters ideal aquele que maximiza esse valor médio.

A aplicação do Método da Silhueta geralmente envolve dois gráficos distintos. O primeiro, exemplificado na Figura 5, apresenta a média do índice de silhueta para diferentes números de grupos (k) e é utilizado para selecionar o número ótimo de clusters (neste exemplo, $k = 3$, o ponto de maior valor). O segundo gráfico, ilustrado na Figura 6, é gerado após a Clusterização com o k escolhido e serve como ferramenta de validação final, permitindo analisar a coesão e a separação de cada observação e cluster individualmente.




Figura 5: Exemplo ilustrativo do *Silhouette Method*. Fonte: adaptado de *Introdução ao Machine Learning — Grupo DataAt (2023)* (dataat.github.io).




Figura 6: Exemplo ilustrativo do *Silhouette Method*. Fonte: adaptado de *LinkedIn Pulse — Diego Parra (2023)* (linkedin.com).

De acordo com Hair et al. (2009), o método da silhueta complementa o método do cotovelo por fornecer uma medida quantitativa de qualidade de agrupamento, permitindo comparar diferentes soluções e validar empiricamente a estrutura obtida. Ambos os critérios foram empregados no presente estudo para definir o número ótimo de clusters, em conjunto com o pacote **NbClust**, garantindo robustez estatística e interpretabilidade aos resultados (CHARRAD et al., 2014).

3 Metodologia

A metodologia deste trabalho foi organizada em três etapas principais: Coleta e Tratamento dos Dados, Análises Estatísticas e Validação dos Resultados. A seguir, a descrição de cada uma dessas etapas de forma detalhada.

3.1 Coleta e Tratamento de Dados

A coleta de dados foi realizada por meio do *Microsoft Excel*, a partir da plataforma *FBref* (fbref.com), que disponibiliza estatísticas detalhadas de desempenho dos jogadores do Campeonato Brasileiro da Série A. Foram utilizados dados referentes à temporada de 2024, contemplando variáveis de natureza ofensiva e defensiva, além de indicadores específicos para goleiros.

Entretanto, o banco de dados original não continha a posição detalhada de cada jogador de linha, apresentando apenas categorias genéricas (defensor, meio-campista ou atacante). Dessa forma, foi necessário acessar a API da plataforma *Transfermarkt* (transfermarkt.com.br.com) para obter as posições específicas de cada atleta e, assim, enriquecer a base de dados com informações mais precisas e adequadas às análises subsequentes.

3.1.1 Conjunto de dados

O conjunto de dados da plataforma *FBref* (fbref.com) contém uma ampla variedade de variáveis que mensuram o desempenho dos jogadores em diferentes aspectos do jogo. Ao todo, foram consideradas 128 variáveis referentes aos jogadores de linha e 42 variáveis específicas para goleiros. As Seções A e B, apresentadas em anexo, descrevem o nome e a definição de cada uma dessas variáveis.

3.1.2 Preparação e Limpeza dos Dados

Após a coleta, os dados passaram por um rigoroso processo de preparação e limpeza, necessário para garantir a consistência das variáveis utilizadas na Análise Fatorial. As principais etapas foram:

- **Correção das posições específicas dos jogadores:** As posições detalhadas dos jogadores de linha foram obtidas na plataforma *Transfermarkt* (transfermarkt.com.br.com), utilizando nome, idade e clube como chaves de identificação. Alguns atletas preci-

saram ser renomeados, pois apareciam com apelidos ou nomes incompletos;

- **Tratamento de jogadores que atuaram por mais de um clube:** Jogadores (de linha ou goleiros) que integraram mais de uma equipe ao longo da temporada tiveram suas métricas agrupadas. Para variáveis expressas como proporções, taxas ou percentuais, foi necessário recalcular manualmente os valores;
- **Conversão das variáveis para formato numérico:** Todas as métricas selecionadas para a Análise Fatorial foram convertidas para o tipo numérico. Variáveis descritivas não foram utilizadas na Análise Fatorial:
 - **Goleiros:** *Player, Nation, Pos, Squad, Age*;
 - **Jogadores de linha:** *Player, Nation, Position, Squad, Age, Born*.

As variáveis *(Playing Time) 90s* e *(Team Success) onGA* não entraram na Análise Fatorial, mas foram utilizadas como pesos no cálculo do score final de goleiros e zagueiros. O restante das variáveis está presente, em anexo, nas Seções A e B;

- **Tratamento de valores ausentes (NA):** Muitas métricas eram razões (ex.: *(Standard) G/Sh*: Gols por chutes realizados). Jogadores que não realizaram determinada ação apresentavam *NA*, o que inviabiliza a Análise Fatorial. Esses valores foram substituídos por zero, sendo coerente com a interpretação das métricas;
- **Remoção de variáveis que eram combinações de outras:** Foram excluídas variáveis derivadas cujas fórmulas eram calculadas diretamente a partir de outras métricas do banco (por exemplo, somas, razões ou proporções). Como essas variáveis são combinações de outras, elas introduzem redundância e prejudicam a matriz de correlação utilizada na Análise Fatorial. As variáveis removidas foram:
 - **Goleiros:** *(Performance) Save%*, *(Performance) CS%*, *(Penalty Kicks) PKA*, *(Penalty Kicks) PKsv*, *(Penalty Kicks) PKm*, *(Expected) PSxG/SoT*, *(Expected) PSxG+/-*, *(Launched) Cmp%*, *(Crosses) Stp%*.
 - **Jogadores de linha:** *(Performance) G+A*, *(Performance) PK*, *(Expected) np:G+xAG*, *(Standard) SoT%*, *(Standard) G/Sh*, *(Standard) G/SoT*, *(Expected) np:G/Sh*, *(Expected) G-xG*, *(Expected) np:G-xG*, *(Total) Cmp%*, *(Short) Cmp%*, *(Medium) Cmp%*, *(Long) Cmp%*, *(Expected) A-xAG*, *(SCA) SCA*, *(GCA) GCA*, *(Tackles) Tkl*, *(Challenges) Tkl%*, *(Challenges) Lost*, *(Blocks) Blocks*, *(Blocks) Tkl+Int*, *(Touches) Live*, *(Take-Ons) Succ%*, *(Take-Ons) Tkld%*, *(Aerial Duels) Won%*.

- **Remoção de variáveis com desvio padrão nulo ou NA:** Variáveis sem variação não contribuem à Análise Fatorial e foram excluídas automaticamente;
- **Remoção de variáveis que eram combinações lineares exatas de outras:** A função `findLinearCombos()` (pacote `caret`) foi utilizada para identificar combinações lineares perfeitas entre as variáveis, isto é, situações em que uma variável pode ser escrita exatamente como uma combinação de outras, por exemplo:

$$v_3 = a \cdot v_1 + b \cdot v_2.$$

Essa etapa foi fundamental porque algumas dessas relações não eram evidentes a priori ou não haviam sido percebidas manualmente durante o processo de limpeza inicial. Além disso, como as relações entre as métricas variam de acordo com a posição dos jogadores (goleiros, zagueiros, laterais, volantes, meias, pontas e atacantes), o conjunto de variáveis removidas também variou entre as posições.

Quando a função identifica uma combinação linear perfeita, ela retorna o conjunto de variáveis que participam dessa relação. O critério de remoção consiste em excluir a variável que é matematicamente derivada das outras. Essa variável derivada é sempre a mais redundante, pois seu valor depende integralmente das variáveis originais. Assim, preservam-se as variáveis fundamentais (aquelas que entram na fórmula) e remove-se apenas a variável resultante, evitando singularidade na matriz de correlação utilizada na Análise Fatorial;

- **Remoção de variáveis altamente correlacionadas ($cutoff = 0,99$):** Para identificar pares de variáveis com correlação quase perfeita, utilizou-se a função `findCorrelation()` do pacote `caret`. Essa função recebe como entrada a matriz de correlação original e retorna os índices das variáveis que devem ser removidas para reduzir redundância informacional. No presente estudo, adotou-se o ponto de corte de 0,99, aplicado especialmente para meias e atacantes, onde algumas métricas apresentavam dependência quase total.

A função opera da seguinte forma: quando dois ou mais preditores exibem correlação absoluta acima do *cutoff*, ela identifica o par altamente correlacionado e calcula, para cada variável, a média das correlações absolutas com todas as demais variáveis do conjunto. Em seguida, remove aquela que apresenta maior correlação média global, isto é, a variável mais redundante dentro do conjunto. Esse critério evita subjetividade e garante que a variável excluída seja a que menos agrega informação própria ao modelo;

- **Padronização das variáveis:** Todas as variáveis numéricas foram padronizadas com a função `scale()`, tornando cada coluna com média 0 e desvio padrão 1.

3.2 Análises Estatísticas

3.2.1 Análise das Correlações

Como etapa inicial da análise exploratória dos dados, procedeu-se à investigação da estrutura de correlações entre as variáveis do estudo. Essa análise é fundamental para compreender o grau de associação linear entre os indicadores e avaliar a adequação do conjunto de dados à aplicação de métodos multivariados.

A matriz de correlações foi estimada diretamente a partir das variáveis originais, sem a realização de padronização prévia. Ressalta-se que tal procedimento não compromete a análise, uma vez que o coeficiente de correlação de Pearson é adimensional e invariável à escala de medida, capturando exclusivamente a intensidade e o sentido da associação linear entre as variáveis.

3.2.2 Análise Fatorial

A Análise Fatorial adotada neste estudo possui caráter exploratório, tendo como objetivo identificar estruturas latentes subjacentes ao conjunto de variáveis analisadas, sem a imposição prévia de um modelo teórico rigidamente definido. Essa abordagem é adequada quando se busca compreender os padrões de correlação entre os itens e investigar a dimensionalidade dos dados, permitindo que a estrutura fatorial emergja empiricamente a partir da matriz de correlações observada. Dessa forma, a Análise Fatorial Exploratória mostrou-se apropriada para orientar a interpretação dos fatores e subsidiar etapas posteriores de validação e aprofundamento analítico.

Avaliação da adequação dos dados

A primeira etapa consistiu em avaliar a adequação dos dados à Análise Fatorial por meio do índice KMO (*Kaiser-Meyer-Olkin*), removendo-se variáveis com valores inferiores a 0,5 por apresentarem baixa correlação parcial com o conjunto. Após essa filtragem inicial, testou-se a normalidade univariada das variáveis por meio do teste de Shapiro–Wilk; contudo, todas as variáveis rejeitaram a hipótese de normalidade.

Definição do número de fatores

Em seguida, procedeu-se à definição do número de fatores a serem extraídos, adotando três critérios amplamente recomendados: (i) o *critério de Kaiser*, que retém fatores com autovalores maiores que 1; (ii) a inspeção visual do *scree plot*, observando o ponto de inflexão da curva; e (iii) a Análise Paralela, utilizada como principal referência por ser considerada o método mais robusto para identificação da dimensionalidade adequada.

Execução da análise fatorial e depuração das variáveis

Com a dimensionalidade definida, a Análise Fatorial foi estimada pelo método de extração Mínimos Resíduos (*Minimum Residuals* – MINRES), escolhido por não exigir normalidade dos dados, característica especialmente relevante considerando que todas as variáveis haviam rejeitado a hipótese de normalidade no teste de Shapiro–Wilk. A solução foi posteriormente submetida à rotação *oblimin*, do tipo oblíqua, permitindo que os fatores se correlacionassem, característica compatível com métricas de desempenho esportivo, que naturalmente apresentam interdependências. Os scores fatoriais individuais foram calculados pelo método *regression*, gerando valores contínuos padronizados para cada jogador e possibilitando comparações consistentes.

A estrutura fatorial resultante foi avaliada segundo as recomendações de Hair et al. (2009), especialmente no que se refere às comunalidades. Variáveis com comunalidade inferior a 0,5 foram consideradas inadequadas por não contribuírem suficientemente para a explicação dos fatores latentes e, portanto, foram removidas.

Reexecução e avaliação dos resultados

Após a depuração, o índice KMO (*Kaiser-Meyer-Olkin*) foi novamente calculado e a Análise Fatorial foi novamente estimada, garantindo uma estrutura mais consistente e interpretável. Em seguida, os principais índices de ajuste fornecidos pelo modelo (como RMSEA, RMSR, TLI, Fit e Variância Explicada) foram analisados, permitindo avaliar a qualidade global da solução.

Interpretação e nomeação de cada fator

Depois disso, foi feita uma análise minuciosa das cargas fatoriais, das comunalidades e das unicidades. As cargas fatoriais são particularmente cruciais, pois indicam a

intensidade da correlação entre as variáveis observadas (métricas de desempenho) e cada fator latente. Variáveis com altas cargas (próximas de $+1$ ou -1) em um determinado fator contribuem significativamente para a sua definição.

Baseando-se neste padrão de cargas fatoriais, observando o conjunto de métricas que "carregam" mais fortemente em cada fator, foi possível realizar a interpretação conceitual de cada dimensão. Em essência, o fator é interpretado como o conceito que o grupo de variáveis correlacionadas está medindo.

Cálculo dos scores

Os cálculos dos scores foram realizados seguindo o processo de agregação dos scores de cada fator:

1. Primeiramente, cada score fatorial individual foi extraído e normalizado entre 0 – 100. Este procedimento foi crucial para mitigar quaisquer distorções numéricas que pudessem surgir das diferentes escalas dos fatores originais;
2. Em seguida, o score normalizado de cada fator foi ponderado pela respectiva proporção da variância explicada por esse fator;
3. Finalmente, esses scores ponderados foram somados para gerar o Score Final.

Para as posições de goleiro e zagueiro, foi identificada a necessidade de um ajuste adicional. O Score Final original era tendencioso, favorecendo indevidamente jogadores de equipes com baixo desempenho defensivo. Para corrigir isso, o Score Final desses atletas foi reponderado pela razão entre a quantidade de gols sofridos (*Team Success*) *onGA* e a quantidade de partidas jogadas (*Playing Time*) *90s*.

3.2.3 Clusterização pelo Método *K-means*

Definição do número de clusters

A definição do número de clusters foi realizada utilizando três métodos distintos: o Método do Cotovelo (Elbow Method), o Método Silhouette e a técnica de seleção de número de clusters do pacote *NbClust*. O Método do Cotovelo é utilizado para identificar o ponto em que a variabilidade explicada pelos clusters começa a apresentar uma diminuição marginal, sugerindo o número ideal de clusters. O Método Silhouette, por

sua vez, apresenta a média do índice de silhueta para diferentes números de grupos (k), para selecionar o número ótimo de clusters. Por fim, o **NbClust** aplica uma combinação de índices diferentes para determinar o número de clusters mais adequado, considerando diferentes aspectos da estrutura dos dados.

Execução da clusterização

Após a definição do número ideal de clusters, a Clusterização foi realizada utilizando o Método *K-means*. Em seguida, os clusters foram renomeados para garantir que os jogadores com os maiores scores finais fossem alocados no cluster 1, seguidos pelos jogadores com pontuação decrescente, que foram distribuídos nos clusters subsequentes (cluster 2, cluster 3, e assim por diante).

Essa abordagem assegura que os jogadores de maior destaque, de acordo com os escores obtidos, fossem agrupados no primeiro cluster, refletindo sua superioridade em relação aos demais jogadores, enquanto os demais clusters reuniram os jogadores com desempenho progressivamente inferior.

Avaliação da clusterização

A qualidade dos clusters foi inicialmente avaliada utilizando o Método Silhouette, que mede o quão bem cada ponto está agrupado em relação aos outros clusters. Esse método ajuda a determinar se a estrutura dos clusters é bem definida e se os elementos dentro de cada cluster são coesos. Para aprofundar a análise, foi realizado o teste de Kruskal-Wallis, com o objetivo de verificar se existem diferenças estatisticamente significativas entre os clusters. Após a confirmação de uma diferença significativa, o teste de Dunn foi aplicado para realizar comparações múltiplas entre os clusters, permitindo avaliar as diferenças de forma mais detalhada, dois a dois.

Interpretação e perfil de cada cluster

Para entender melhor o perfil de cada cluster, foi gerado um boxplot, que permite visualizar a distribuição dos scores finais dentro de cada grupo. Em seguida, foi realizada uma análise comparativa dos scores fatoriais individuais dentro de cada cluster, a fim de identificar as características predominantes e os perfis dos atletas em cada grupo. Essa abordagem possibilita uma compreensão mais aprofundada das diferenças entre os clusters e como os jogadores se distribuem em relação aos fatores que influenciam seu desempenho.

3.3 Validação dos Resultados

A validação dos resultados obtidos nos modelos de desempenho foi realizada por meio da comparação dos scores finais com duas referências amplamente reconhecidas no cenário esportivo nacional: a Seleção do Campeonato divulgada pelo portal GE (GE, 2024) e a premiação Bola de Prata organizada pela ESPN (RESENDE, 2024). Essas duas fontes independentes são compostas por especialistas, jornalistas e critérios consolidados de avaliação, o que permite utilizá-las como parâmetros externos para aferir a coerência dos indicadores construídos neste estudo.

A comparação consistiu em verificar se os jogadores que apresentaram os maiores escores em suas respectivas posições também aparecem com destaque nas seleções divulgadas por essas instituições. A consistência entre as avaliações externas e as pontuações calculadas neste trabalho reforça a validade prática dos modelos utilizados, indicando que as medidas estatísticas aplicadas conseguem capturar o desempenho observado ao longo da temporada.

3.4 Ferramentas e Softwares Utilizados

A análise foi conduzida majoritariamente no software R, utilizado nas etapas de pré-processamento de dados, análises estatísticas (Análise Fatorial e Clusterização) e elaboração de gráficos. Além disso, empregou-se o Python para acessar a API do *Transfermarkt* (transfermarkt.com.br.com) e obter as posições detalhadas de cada jogador.

4 Resultados

4.1 Análise das Correlações

4.1.1 Goleiros

A Figura 7 ilustra o mapa de calor da matriz de correlações de Pearson entre as 35 variáveis numéricas analisadas para os goleiros, permitindo uma visão geral das associações lineares e da presença de grupos de métricas fortemente relacionadas.




Figura 7: Mapa de calor da matriz de correlações para Goleiros.

De forma geral, observa-se uma predominância de correlações positivas, com coeficientes variando de valores fracos a muito elevados. A distribuição dos coeficientes apresenta mediana em torno de 0,19 e média aproximada de 0,29, indicando que, embora muitas associações sejam de baixa a moderada magnitude, há um conjunto relevante de pares de variáveis fortemente correlacionados.

As correlações mais elevadas concentram-se entre variáveis de ações defensivas do goleiro, como finalizações sofridas, defesas realizadas e métricas esperadas (*PSxG*), indicando que essas variáveis capturam uma mesma dimensão latente associada à pressão defensiva e à prevenção de gols. Adicionalmente, observam-se altas correlações entre indicadores de reposição de bola e jogo com os pés, sugerindo uma dimensão comum relacionada à participação do goleiro na construção e progressão das jogadas. Esses blocos

de alta correlação evidenciam redundância informacional e confirmam a adequação dos dados para técnicas de redução de dimensionalidade.

4.1.2 Jogadores de Linha

A Figura 8 apresenta o mapa de calor da matriz de correlações de Pearson entre as 120 variáveis numéricas dos jogadores de linha, permitindo visualizar padrões globais de associação linear e grupos de métricas fortemente correlacionadas.




Figura 8: Mapa de calor da matriz de correlações para Jogadores de Linha.

Em termos gerais, verifica-se a predominância de correlações positivas, com coeficientes que variam de moderados a elevados. A distribuição apresenta mediana em torno de 0,29 e média aproximada de 0,34, indicando que, apesar da presença de muitas associações de baixa a moderada intensidade, existe um contingente significativo de pares de variáveis com correlações fortes.

Observam-se correlações muito elevadas entre variáveis que medem aspectos semelhantes do desempenho, indicando elevada redundância informacional. Esse padrão é evidente tanto em métricas ofensivas, como passes, volume de ações com bola, progressão territorial, gols e indicadores esperados, quanto em métricas defensivas, incluindo desarmes, bloqueios, interceptações e duelos. Tais associações refletem a presença de dimensões latentes comuns e estruturas internas consistentes no desempenho ofensivo e defensivo. Esses padrões confirmam a consistência interna dos dados e reforçam sua adequação para métodos de redução de dimensionalidade, como a Análise Fatorial Exploratória.

4.2 Análise dos Goleiros

A análise considerou os goleiros que atuaram pelos 20 clubes do Campeonato Brasileiro da Série A de 2024, totalizando 45 atletas, sendo a maioria brasileiros (41), além de representantes da Argentina, Paraguai e Uruguai. As idades variaram de 19 a 43 anos, com média de 28,69 anos, refletindo um grupo heterogêneo composto por jogadores jovens e experientes.

O conjunto de dados incluiu 42 variáveis (Anexo B), das quais 5 eram descritivas (*Player*, *Nation*, *Pos*, *Squad* e *Age*) e não integraram a Análise Fatorial. As variáveis (*Playing Time*) *90s* e (*Team Success*) *onGA* foram excluídas da formação dos fatores, mas utilizadas posteriormente para ponderação do score final. Assim, 35 variáveis compuseram o conjunto de indicadores utilizado na extração dos fatores.

4.2.1 Preparação e Limpeza dos Dados

Os dados foram tratados conforme a Seção 3.1.2, consolidando atletas que atuaram por mais de um clube, removendo variáveis descritivas e tratando valores ausentes. Variáveis redundantes ou sem variação foram excluídas, e todas as demais foram padronizadas em escala *z*. Ao final, obteve-se um conjunto limpo e consistente de 26 variáveis para aplicação da Análise Fatorial.

4.2.2 Análise Fatorial

Avaliação da adequação dos dados

A adequação das variáveis foi avaliada pelo índice KMO, mantendo-se apenas aquelas com valor individual acima de 0,5. O KMO global de 0,834 indicou excelente qualidade da matriz de correlações. Além disso, o teste de Shapiro–Wilk revelou ausência de normalidade, reforçando a necessidade de métodos de extração mais robustos para a Análise Fatorial.

Definição do número de fatores

A definição da dimensionalidade baseou-se nos três critérios aplicados. O *critério de Kaiser* e o *scree plot* (Figura 9) sugeriram a extração de 2 fatores, enquanto a Análise Paralela (Figura 10), reconhecida como o método mais robusto, indicou a retenção de

apenas 1.




Figura 9: *Scree plot* para Goleiros.




Figura 10: Análise Paralela para Goleiros.

Assim, optou-se pela extração de 1 único fator, privilegiando parcimônia e aderência às evidências empíricas.

Execução da análise fatorial e depuração das variáveis

Com o número de fatores definido, estimou-se o modelo unifatorial utilizando o método MINRES, adequado para dados não normais, com rotação oblíqua (*oblimin*). Os scores fatoriais foram obtidos por regressão e, durante essa etapa, removeram-se as variáveis com comunalidade inferior a 0,5, garantindo que apenas indicadores com contribuição relevante ao fator principal permanecessem na solução final.

Reexecução e avaliação dos resultados

Após remover variáveis de baixa comunalidade, o KMO foi recalculado para as 14 variáveis finais, alcançando 0,863. A Análise Fatorial unifatorial foi então reexecutada com o método MINRES, rotação *oblimin* e cálculo de scores por regressão.

Tabela 1: Medidas de Ajuste do Modelo Fatorial Unifatorial para Goleiros

Indicador	Valor
RMSEA	0,353
RMSR	0,034
TLI	0,679
Fit (off-diagonal)	0,999
Variância Explicada	87,3%

A Tabela 1 apresenta as medidas de ajuste do modelo. Apesar de RMSEA e TLI não indicarem ajuste ideal, o modelo mostra resíduos baixos, excelente reprodução das correlações e alta variância explicada, evidenciando que a estrutura latente central é bem capturada.

Interpretação e nomeação de cada fator

A análise das cargas fatoriais, comunalidades e unicidades (Tabela 29, no Apêndice) revelou forte associação das variáveis ao fator extraído, indicando uma estrutura latente bem definida. As comunalidades elevadas e unicidades baixas mostram que o fator explica grande parte da variabilidade das métricas. Assim, o fator foi denominado **Desempenho Global**, por sintetizar em uma única dimensão as principais ações defensivas dos goleiros ao longo da temporada.

Cálculo dos scores

O score individual de cada goleiro foi obtido a partir do fator único extraído e posteriormente normalizado para uma escala de 0 a 100. Durante essa etapa, identificou-se uma correlação indesejada entre o Score Final e os gols sofridos (*Team Success — onGA*), com valor de 0,93. Para corrigir esse viés, construiu-se um indicador ajustado, gols sofridos por 90 minutos, utilizado para ponderar o score de forma inversa, garantindo que a avaliação refletisse melhor o desempenho real dos goleiros.

Tabela 2: Top 5 Goleiros.

Ranking	Jogador	Clube	Score Final
1	John	Botafogo	46,1
2	João Ricardo	Fortaleza	44,9
3	Weverton	Palmeiras	42,8
4	Fábio	Fluminense	42,7
5	Marcos Felipe	Bahia	41,3

A Tabela 2 apresenta os cinco goleiros mais bem avaliados, com desempenho equilibrado entre os primeiros colocados.

4.2.3 Clusterização pelo Método *K-means*

Com o objetivo de avaliar se o Score Final distingue perfis de desempenho entre os goleiros, aplicou-se a Clusterização pelo Método *K-means*. Essa análise verifica se os atletas se agrupam de forma consistente segundo o indicador, reforçando sua capacidade de diferenciar níveis de performance.

Definição do número de clusters

A escolha do número de clusters baseou-se em três critérios. O Método do Cotovelo (Figura 11) indica um ponto de inflexão em $k = 2$, enquanto o Método da Silhueta (Figura 12) mostra seu maior valor médio também para $k = 2$. De forma complementar, a função NbClust apontou a mesma solução pela regra da maioria.




Figura 11: Método do Cotovelo para definição do número de clusters dos Goleiros.




Figura 12: Método da Silhueta para definição do número de clusters dos Goleiros.

Dessa forma, considerando os três métodos, Cotovelo, Silhueta e consenso do *NbClust*, definiu-se que a solução mais adequada para os dados dos goleiros é composta por 2 clusters.

Execução da clusterização

Com o número de grupos definido, aplicou-se o algoritmo *K-means* aos scores finais. Após o agrupamento, os clusters foram reorganizados para interpretação, definindo-se o grupo de maiores scores como Cluster 1 e o de desempenho inferior como Cluster 2.

Avaliação da clusterização

A qualidade da clusterização foi analisada por meio do índice de Silhueta e de testes estatísticos. O gráfico da Figura 13 mostra silhuetas médias altas para ambos os clusters, indicando boa separação e coesão interna.




Figura 13: Gráfico de Silhueta para $k = 2$ na clusterização dos Goleiros.

Para verificar se os grupos diferem estatisticamente em termos de Score Final, aplicou-se o teste de Kruskal–Wallis. A Tabela 3 apresenta os resultados, que indicam diferenças altamente significativas entre os clusters.

Tabela 3: Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Goleiros.

H	p -valor	Decisão
31,043	$2,523 \times 10^{-8}$	Rejeita H_0

Em conjunto, esses resultados mostram que o Score Final diferencia de forma consistente os goleiros, validando sua capacidade discriminativa.

Interpretação e perfil de cada cluster

A Figura 14 mostra dois grupos bem definidos com base no Score Final. O Cluster 1 concentra goleiros com valores mais altos, indicando desempenho superior ao longo da temporada. Já o Cluster 2 reúne atletas com scores inferiores, refletindo menor efetividade nas ações avaliadas.




Figura 14: Distribuição do Score Final dos Goleiros por cluster.

Os perfis podem ser resumidos da seguinte forma:

- **Cluster 1 — Goleiros de Alta Performance:** destacam-se pela eficiência defensiva, boa proteção da meta e participação qualificada com os pés;
- **Cluster 2 — Goleiros de Desempenho Inferior:** apresentam menor efetividade nas defesas, maior vulnerabilidade a finalizações e menor participação na construção das jogadas.

4.2.4 Validação dos Resultados

A validação do modelo foi realizada comparando o ranking obtido pelo Score Final com as principais premiações da temporada. O goleiro John, líder da Tabela 2, também foi eleito o melhor goleiro tanto pela Seleção do Brasileirão 2024 do GE (GE, 2024) quanto pelo Prêmio ESPN Bola de Prata (RESENDE, 2024). Essa convergência entre o modelo estatístico e as avaliações da imprensa esportiva reforça a validade externa do indicador construído.

4.3 Análise dos Zagueiros

A análise dos zagueiros englobou os atletas que atuaram pelos 20 clubes participantes do Campeonato Brasileiro da Série A de 2024, totalizando 116 jogadores. A maioria é formada por brasileiros (92), complementados por atletas de diversas nacionalidades, incluindo Argentina, Uruguai, Colômbia, Portugal, Equador, Paraguai, Angola, Chile e Venezuela. As idades variam entre 16 e 39 anos, com média de 26,76 anos, indicando um grupo amplo e diverso, que reúne tanto jovens promissores quanto jogadores mais experientes.

O banco de dados analisado continha 128 variáveis (Anexo A), das quais 6 tinham caráter exclusivamente descritivo (*Player*, *Nation*, *Position*, *Squad*, *Age* e *Born*) e, por essa razão, foram excluídas da etapa de Análise Fatorial. As variáveis (*Playing Time*) *90s* e (*Team Success*) *onGA* também não integraram a extração dos fatores, sendo utilizadas posteriormente apenas para o ajuste do score final, permitindo ponderar o desempenho segundo tempo em campo e gols sofridos pela equipe. Assim, 120 variáveis numéricas permaneceram e foram utilizadas na extração dos fatores.

4.3.1 Preparação e Limpeza dos Dados

A preparação dos dados dos zagueiros seguiu o protocolo geral da Seção 3.1.2, incluindo a incorporação das posições do *Transfermarkt*. Aplicou-se o mesmo fluxo de limpeza utilizado para os goleiros: consolidação de atletas que atuaram por mais de um clube, remoção de variáveis descritivas, conversão das métricas para formato numérico e tratamento de ausências. Variáveis redundantes ou sem variação foram excluídas, e as demais padronizadas em escala *z*, totalizando 89 indicadores para a Análise Fatorial.

4.3.2 Análise Fatorial

Avaliação da adequação dos dados

A adequação das variáveis dos zagueiros foi verificada pelo índice KMO, mantendo-se apenas aquelas com valor individual acima de 0,5. O conjunto final, com 78 variáveis, apresentou KMO global de 0,861, classificado como “muito bom”, confirmando a qualidade da matriz de correlações. O teste de Shapiro–Wilk apontou ausência de normalidade, justificando métodos de extração apropriados para dados não normais.

Definição do número de fatores

A definição do número de fatores para os zagueiros foi orientada pelos três critérios tradicionais. O *critério de Kaiser* sugeriu uma solução extensa, com 10 fatores, enquanto o *scree plot* (Figura 15) revelou uma queda acentuada no primeiro componente seguida de longa estabilização, indicando uma estrutura bem menos complexa. Já a Análise Paralela (Figura 16), reconhecida como a abordagem mais robusta para essa decisão, apontou a retenção de 4 fatores.




Figura 15: *Scree plot* para Zagueiros.




Figura 16: Análise Paralela para Zagueiros.

Diante desses resultados, adotou-se a solução com 4 fatores, equilibrando parcimônia e coerência estatística, e seguindo a indicação mais confiável fornecida pela Análise Paralela.

Execução da análise fatorial e depuração das variáveis

Com a dimensionalidade definida, ajustou-se o modelo fatorial para os zagueiros utilizando o método de extração MINRES, adequado à ausência de normalidade, e rotação oblíqua (*oblimin*). Os scores fatoriais foram calculados pelo método de regressão. Durante essa etapa, foram removidas todas as variáveis com comunalidade inferior a 0,5, garantindo que apenas indicadores com contribuição substantiva aos fatores fossem mantidos na solução final.

Reexecução e avaliação dos resultados

Após remover as variáveis com comunalidade inferior a 0,5, recalculou-se o KMO para as 63 variáveis remanescentes, alcançando 0,896 (“muito bom”). O modelo com 4 fatores foi então reestimado usando o método MINRES, rotação *oblimin* e cálculo dos scores por regressão.

Tabela 4: Medidas de Ajuste do Modelo Fatorial com 4 Fatores para Zagueiros

Indicador	Valor
RMSEA	0,198
RMSR	0,031
TLI	0,548
Fit (off-diagonal)	0,998
Variância Explicada	82,7%

A Tabela 4 resume as medidas de ajuste. Embora alguns índices não indiquem ajuste ideal, o modelo apresenta resíduos baixos, alta capacidade de reproduzir as correlações e elevada variância explicada, evidenciando boa captura da estrutura latente.

Interpretação e nomeação de cada fator

A análise das cargas fatoriais, comunalidades e unicidades (Tabela 30, no Apêndice) revelou quatro dimensões bem estruturadas, com comunalidades altas e unicidades baixas, indicando boa explicação da variabilidade pelas dimensões extraídas.

O Fator 1, responsável por 44% da variância, reúne ações de passe, progressões e conduções, sendo interpretado como **Saída de Jogo**. O Fator 2, que explica 17,8%, concentra métricas de apoio ofensivo e ligação com o meio-campo, caracterizando **Cons-**

trução e Ligação. O Fator 3, com 10,7% da variância, agrupa indicadores ofensivos diretos, como finalizações e xG , sendo nomeado **Ação Ofensiva Direta**. Por fim, o Fator 4, responsável por 10,3%, reúne ações defensivas e duelos, representando **Duelos e Contenção**.

Esses quatro fatores sintetizam os principais domínios técnico-táticos que definem o desempenho dos zagueiros ao longo da temporada.

Cálculo dos scores

Para os zagueiros, os scores individuais foram inicialmente obtidos a partir dos 4 fatores extraídos e normalizados para uma escala comum de 0 a 100. Em seguida, construiu-se o Score Geral por meio de uma ponderação dos scores fatoriais pelas respectivas variâncias explicadas, resultando em uma medida única de desempenho global.

Durante a inspeção dos resultados, observou-se um problema semelhante ao encontrado nos goleiros: os zagueiros mais bem ranqueados eram justamente aqueles com maior número de gols sofridos pela equipe. A correlação entre o Score Geral e os gols sofridos (*Team Success — onGA*) foi de 0,82, indicando um viés indesejado. Para corrigir essa distorção, aplicou-se o mesmo ajuste utilizado para os goleiros, ponderando o Score Final de forma inversamente proporcional aos gols sofridos por 90 minutos, garantindo uma avaliação mais fiel ao desempenho defensivo.

Tabela 5: Top 5 Zagueiros.

Ranking	Jogador	Clube	Score Final
1	Alexander Barboza	Botafogo	40,1
2	Bastos	Botafogo	36,7
3	Murilo	Palmeiras	35,3
4	Alan Empereur	Cuiabá	34,1
5	Thiago Santos	Fluminense	33,9

A Tabela 5 apresenta os cinco zagueiros mais bem avaliados segundo o Score Final, já ajustado pelo indicador defensivo, permitindo uma comparação mais adequada entre os atletas.

4.3.3 Clusterização pelo Método *K-means*

Para verificar se o Score Final diferencia níveis de desempenho entre os zagueiros, aplicou-se a Clusterização pelo algoritmo *K-means*. Essa análise avalia se os atletas se agrupam de forma consistente segundo o indicador, reforçando sua capacidade de identificar perfis distintos de performance.

Definição do número de clusters

A definição do número ideal de grupos foi guiada por três abordagens. O Método do Cotovelo (Figura 17) sugere estabilização da inércia em torno de $k = 3$ ou $k = 4$, enquanto o Método da Silhueta (Figura 18) apresenta melhores resultados próximos de $k = 5$, ainda que $k = 3$ e $k = 4$ também sejam consistentes. A função NbClust apontou 4 clusters como solução preferencial.




Figura 17: Método do Cotovelo para definição do número de clusters dos Zagueiros.




Figura 18: Método da Silhueta para definição do número de clusters dos Zagueiros.

Considerando o conjunto das evidências, avaliou-se $k = 3$, $k = 4$ e $k = 5$, sendo a solução com 3 clusters a que apresentou melhor equilíbrio entre coerência estatística e interpretabilidade, e portanto adotada.

Execução da clusterização

Com o número de grupos definido, aplicou-se o algoritmo *K-means* aos scores finais dos zagueiros. Após o particionamento, os clusters foram ordenados para facilitar a interpretação, definindo o grupo de maior desempenho como Cluster 1 e os demais em sequência decrescente.

Avaliação da clusterização

A qualidade da clusterização para os zagueiros foi examinada a partir do índice de Silhueta e de testes estatísticos. O gráfico da Figura 19 apresenta silhuetas médias satisfatórias para os três grupos formados, o que indica boa coesão interna e separação razoável entre os clusters.




Figura 19: Gráfico de Silhueta para $k = 3$ na clusterização dos Zagueiros.

Para verificar se os clusters diferem estatisticamente quanto ao Score Final, aplicou-se o teste de Kruskal–Wallis. Os resultados da Tabela 6 mostram diferenças altamente significativas entre os grupos, indicando que a clusterização é consistente em termos de separação dos níveis de desempenho.

Tabela 6: Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Zagueiros.

H	p -valor	Decisão
96,725	$< 2.2 \times 10^{-16}$	Rejeita H_0

Diante da significância global, realizou-se o teste de Dunn. A Tabela 7 indica que todas as comparações par-a-par apresentaram diferenças significativas, o que reforça a existência de três grupos bem distintos em termos de desempenho.

Tabela 7: Resultado do teste de Dunn para comparações múltiplas entre os clusters dos Zagueiros.

Comparação	Z	p -valor	Decisão
1 – 2	4,876	$3,24 \times 10^{-6}$	Diferença significativa
1 – 3	9,724	$7,13 \times 10^{-22}$	Diferença significativa
2 – 3	6,099	$3,20 \times 10^{-9}$	Diferença significativa

Também foram avaliadas as soluções com $k = 4$ e $k = 5$. Embora apresentassem separações visuais razoáveis, o teste de Dunn indicou falta de diferenças significativas entre alguns grupos, reduzindo a interpretabilidade. Assim, a solução com 3 clusters mostrou o melhor equilíbrio entre separação estatística e clareza analítica.

Interpretação e perfil de cada cluster

A Figura 20 evidencia três grupos bem definidos, com diferenças claras na distribuição do Score Final. O Cluster 1 apresenta os maiores valores, refletindo um grupo de zagueiros de alta performance. O Cluster 2 ocupa uma faixa intermediária, com desempenho moderado e mais equilibrado. Já o Cluster 3 concentra os jogadores com menores scores, indicando influência reduzida nas diferentes dimensões avaliadas.




Figura 20: Distribuição do Score Final dos Zagueiros por cluster.

A seguir, descrevem-se os perfis detalhados de cada cluster:

- **Cluster 1 — Zagueiros Construtores de Alta Performance:** zagueiros modernos, dominantes nas quatro dimensões avaliadas e que se destacam tanto ofensivamente quanto defensivamente;
- **Cluster 2 — Zagueiros Equilibrados e de Desempenho Intermediário:** zagueiros confiáveis, estáveis e com bom equilíbrio entre defesa e construção, mas sem o caráter decisivo observado no Cluster 1. São atletas com perfil tático sólido e regularidade, porém com menor protagonismo;
- **Cluster 3 — Zagueiros de Baixa Participação e Efetividade:** zagueiros com menor impacto global no jogo, seja na construção, na criatividade, no ataque ou na solidez defensiva.

4.3.4 Validação dos Resultados

A validação do modelo foi conduzida comparando o ranking gerado pelo Score Final com as principais premiações da temporada. Observa-se que Alexander Barboza e Bastos, que lideram a Tabela 5, também figuram entre os zagueiros selecionados na Seleção do Brasileirão 2024 do GE (GE, 2024), enquanto Bastos e Gustavo Gómez foram os escolhidos pelo Prêmio ESPN Bola de Prata (RESENDE, 2024). A correspondência entre o modelo proposto e as seleções oficiais da mídia esportiva reforça a consistência e a credibilidade do indicador desenvolvido.

4.4 Análise dos Laterais

A análise dos laterais considerou 109 atletas que disputaram o Campeonato Brasileiro da Série A de 2024. A maior parte é composta por jogadores brasileiros (82), acompanhados por representantes de diversos países, como Argentina, Uruguai, Paraguai, Colômbia, Equador, Portugal, Espanha, Bulgária, Irlanda do Norte e Peru. As idades variam entre 17 e 38 anos, com média de 26,17 anos, evidenciando um grupo heterogêneo, que reúne desde jovens em desenvolvimento até atletas mais experientes.

A base utilizada continha 128 variáveis relacionadas ao desempenho dos jogadores (Anexo A). Assim como nas outras posições, as variáveis estritamente descritivas foram removidas por não contribuírem para a modelagem estatística. Diferentemente do que ocorreu com goleiros e zagueiros, as métricas (*Playing Time*) 90s e (*Team Success*) onGA não foram utilizadas em nenhuma etapa da análise. Assim, a extração dos fatores foi realizada exclusivamente com 120 variáveis de desempenho técnico e tático.

4.4.1 Preparação e Limpeza dos Dados

A preparação dos dados dos laterais seguiu o protocolo da Seção 3.1.2, incluindo a incorporação das posições do *Transfermarkt*. Aplicou-se o mesmo fluxo de limpeza das demais posições: consolidação de atletas com múltiplos clubes, remoção de variáveis descritivas, padronização das métricas e tratamento de ausências. Variáveis redundantes ou sem variação foram excluídas, resultando em 92 indicadores utilizados na Análise Fatorial.

4.4.2 Análise Fatorial

Avaliação da adequação dos dados

A adequação das variáveis dos laterais foi avaliada pelo índice KMO, preservando apenas aquelas com valor individual acima de 0,5. O conjunto final, com 82 variáveis, apresentou KMO global de 0,855, considerado “muito bom”, indicando boa qualidade da matriz de correlações. O teste de Shapiro–Wilk rejeitou a normalidade em todas as métricas, reforçando o uso de métodos de extração apropriados para dados não normais.

Definição do número de fatores

A determinação do número de fatores para os laterais considerou os três critérios clássicos. O *critério de Kaiser* apontou 9 fatores, mas esse valor tende a superestimar a dimensionalidade. O *scree plot* (Figura 21) mostrou uma queda inicial acentuada seguida de rápida estabilização dos autovalores, sugerindo uma estrutura mais simples. Já a Análise Paralela (Figura 22), reconhecida como o método mais robusto, indicou a retenção de 3 fatores.




Figura 21: *Scree plot* para Laterais.




Figura 22: Análise Paralela para Laterais.

Diante do conjunto de evidências, optou-se pela solução com 3 fatores, por oferecer maior parcimônia e estar alinhada à indicação da Análise Paralela.

Execução da análise fatorial e depuração das variáveis

Com a quantidade de fatores definida, estimou-se o modelo fatorial dos laterais por meio do método MINRES, adequado à ausência de normalidade, utilizando rotação oblíqua (*oblimin*) e cálculo dos scores por regressão. Em seguida, avaliou-se a comunalidade das variáveis, removendo-se aquelas com valores abaixo de 0,5, de forma a manter apenas métricas com participação relevante na variância comum da solução final.

Reexecução e avaliação dos resultados

Com a remoção das variáveis de baixa comunalidade, o conjunto final passou a conter 71 indicadores. O KMO foi recalculado e atingiu 0,873, classificado como “muito bom”, confirmando a adequação dos dados. O modelo com 3 fatores foi então reestimado via MINRES, com rotação *oblimin* e scores por regressão.

Tabela 8: Medidas de Ajuste do Modelo Fatorial com 3 Fatores para Laterais

Indicador	Valor
RMSEA	0,189
RMSR	0,039
TLI	0,510
Fit (off-diagonal)	0,997
Variância Explicada	81,2%

A Tabela 8 resume as medidas de ajuste. Apesar de RMSEA e TLI não indicarem ajuste ideal, o modelo apresenta resíduos baixos, alta capacidade de reproduzir as correlações e elevada variância explicada, evidenciando que a estrutura latente dos laterais é bem representada pelos 3 fatores extraídos.

Interpretação e nomeação de cada fator

A análise das cargas fatoriais (Tabela 31) revelou três dimensões bem definidas, com comunalidades elevadas indicando boa explicação da variabilidade das métricas.

O Fator 1 (55,9% da variância) reúne métricas de passes, conduções e progressões, refletindo **Contribuição Global e Progressão**. O Fator 2 (16,6%) concentra ações ofensivas diretas, como gols, finalizações e dribles, sendo interpretado como **Impacto Ofensivo Direto**. O Fator 3 (8,6%) agrupa cruzamentos e métricas de bolas paradas,

caracterizando **Ações de Cruzamento e Bolas Paradas**.

Esses três fatores sintetizam os principais papéis técnicos e táticos desempenhados pelos laterais ao longo da temporada.

Cálculo dos scores

Para os laterais, os scores individuais foram calculados a partir dos três fatores extraídos e posteriormente normalizados para uma escala comum de 0 a 100. Em seguida, o Score Final foi obtido por meio da ponderação dos scores fatoriais pelas respectivas variâncias explicadas, resultando em uma medida única e comparável de desempenho global.

Diferentemente do ocorrido com goleiros e zagueiros, não foi necessária nenhuma etapa adicional de ajuste, e o indicador final pôde ser utilizado diretamente para ranquear os laterais de forma consistente.

Tabela 9: Top 5 Laterais Direita.

Ranking	Jogador	Clube	Score Final
1	William	Cruzeiro	76,3
2	João Lucas	Juventude	74,6
3	João Pedro	Grêmio	74,2
4	Ewerthon	Juventude	73,0
5	Paulo Henrique	Vasco	72,1

Tabela 10: Top 5 Laterais Esquerda.

Ranking	Jogador	Clube	Score Final
1	Alexandro Bernabei	Internacional	81,9
2	Lucas Esquivel	Athletico PR	80,1
3	Luciano Juba	Bahia	77,4
4	Ramon	Cuiabá	73,5
5	Marcelo Hermes	Criciúma	71,1

A Tabela 9 e a Tabela 10 apresentam os dez laterais, cinco direita e cinco esquerda, mais bem avaliados segundo o Score Final, permitindo identificar os atletas que mais contribuíram para suas equipes ao longo da temporada.

4.4.3 Clusterização pelo Método *K-means*

A Clusterização via *K-means* foi aplicada para avaliar se o Score Final distingue diferentes padrões de desempenho entre os laterais. Essa análise verifica a formação de grupos coerentes a partir do indicador, reforçando sua capacidade de identificar perfis distintos na posição.

Definição do número de clusters

A definição do número ideal de grupos foi orientada por três métodos. O Método do Cotovelo (Figura 23) aponta uma queda acentuada até $k = 2$, com ganhos marginais após esse ponto. O Método da Silhueta (Figura 24) apresenta seu melhor valor médio justamente em $k = 2$. De forma consistente, a função `NbClust` também indicou 2 clusters como solução mais frequente.




Figura 23: Método do Cotovelo para definição do número de clusters dos Laterais.




Figura 24: Método da Silhueta para definição do número de clusters dos Laterais.

Considerando o conjunto das evidências, a solução com 2 clusters apresentou o melhor equilíbrio entre simplicidade, separação e interpretabilidade, sendo adotada para os laterais.

Execução da clusterização

Após a Clusterização, os grupos foram reorganizados para facilitar a interpretação: o cluster com maiores scores foi definido como Cluster 1, seguido pelos demais em ordem decrescente de desempenho. Essa padronização torna a leitura dos níveis de performance mais clara e comparável.

Avaliação da clusterização

A qualidade do agrupamento dos laterais foi examinada por meio do índice de Silhueta e de testes estatísticos. O gráfico da Figura 25 apresenta silhuetas médias elevadas para ambos os grupos, indicando boa coesão interna e separação consistente entre os clusters identificados.




Figura 25: Gráfico de Silhueta para $k = 2$ na clusterização dos Laterais.

Para verificar se os grupos diferem significativamente em termos de Score Final, realizou-se o teste de Kruskal–Wallis. Os resultados, apresentados na Tabela 11, demonstram diferenças altamente significativas entre os clusters.

Tabela 11: Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Laterais.

H	p -valor	Decisão
79,473	$< 2,2 \times 10^{-16}$	Rejeita H_0

Em conjunto, esses achados confirmam que o Score Final separa de forma consistente laterais com diferentes níveis de desempenho, validando sua capacidade discriminativa.

Interpretação e perfil de cada cluster

A Figura 26 revela dois grupos bem separados, com diferenças nítidas na distribuição do Score Final. O Cluster 1 reúne os laterais de maior desempenho, enquanto o Cluster 2 agrupa atletas com participação mais limitada nas três dimensões avaliadas.




Figura 26: Distribuição do Score Final dos Laterais por cluster.

A seguir, apresentam-se os perfis resumidos de cada grupo:

- **Cluster 1 — Laterais de Alta Performance e Grande Influência no Jogo:** atletas com forte influência no jogo, combinando participação elevada na construção, progressão e criação ofensiva, além de bom desempenho em cruzamentos e bolas paradas. Representam laterais completos e decisivos;
- **Cluster 2 — Laterais de Baixa Participação e Menor Efetividade:** jogadores com envolvimento limitado na circulação e progressão, menor impacto ofensivo e atuação menos expressiva em ações de cruzamento e bolas paradas, indicando influência reduzida no jogo.

4.4.4 Validação dos Resultados

Entre os laterais direita, William (Cruzeiro), líder do ranking na Tabela 9, foi escolhido no Prêmio ESPN Bola de Prata (RESENDE, 2024), enquanto Wesley (Flamengo), destaque na Seleção do GE (GE, 2024). No lado esquerdo, Alexandro Bernabei (Internacional), primeiro colocado na Tabela 10, esteve presente tanto na Seleção do GE quanto no Bola de Prata.

Apesar das diferenças pontuais, a recorrência de William e Alexandro Bernabei nas premiações, alinhada ao bom desempenho estimado pelo modelo, indica que o Score Final apresenta coerência externa e reflete adequadamente o desempenho dos volantes ao longo da competição.

4.5 Análise dos Volantes

A análise referente aos volantes considerou 152 jogadores. A maioria absoluta dos atletas é brasileira (126), acompanhada por jogadores da Argentina, Uruguai, Paraguai, Chile, Colômbia, Equador, Peru, Suíça e Venezuela, o que demonstra uma presença internacional moderada dentro da posição. As idades variaram entre 16 e 40 anos, com média de 25,32 anos, indicando um conjunto formado predominantemente por atletas em plena fase competitiva, mas que também inclui tanto jovens iniciando sua trajetória quanto jogadores mais experientes.

A base utilizada para esta posição segue a mesma estrutura geral aplicada aos jogadores de linha, reunindo 128 variáveis técnico-desempenho (Anexo A). Entre elas, algumas possuem caráter estritamente descritivo e, por isso, foram desconsideradas na etapa de Análise Fatorial. Assim como na análise dos laterais, as variáveis (*Playing Time*) 90s e (*Team Success*) onGA também não foram incluídas em nenhuma fase do processo, nem na extração dos fatores nem como forma de ponderação posterior. Dessa forma, a construção dos fatores utilizou exclusivamente as variáveis de desempenho efetivo dos volantes, totalizando 120 indicadores.

4.5.1 Preparação e Limpeza dos Dados

A preparação dos dados dos volantes seguiu o protocolo da Seção 3.1.2, incluindo a incorporação das posições do *Transfermarkt*. Aplicou-se o fluxo padrão de tratamento: consolidação de atletas com múltiplos clubes, remoção de variáveis descritivas, conversão das métricas para formato numérico e tratamento de ausências. Variáveis redundantes, sem variação ou envolvidas em combinações lineares foram removidas. Após a padronização em escala z , o conjunto final foi composto por 92 variáveis para a Análise Fatorial.

4.5.2 Análise Fatorial

Avaliação da adequação dos dados

A adequação das variáveis dos volantes foi avaliada pelo índice KMO, mantendo-se apenas aquelas com valor individual acima de 0,5. Após essa filtragem, o KMO global das 88 variáveis restantes foi de 0,889, classificado como “muito bom”, confirmando a qualidade da matriz de correlações. O teste de Shapiro–Wilk rejeitou a normalidade univari-

ada para todas as métricas, reforçando a necessidade de métodos de extração apropriados para dados não normais.

Definição do número de fatores

A definição do número de fatores para os volantes considerou três critérios. O *critério de Kaiser* sugeriu 11 fatores, mas o *scree plot* (Figura 27) mostra queda inicial acentuada seguida de estabilização, indicando uma estrutura mais enxuta. A Análise Paralela (Figura 28) confirmou a retenção de 6 fatores, pois apenas os seis primeiros autovalores observados superaram os simulados.




Figura 27: *Scree plot* para Volantes.




Figura 28: Análise Paralela para Volantes.

Com base nesse conjunto de evidências, optou-se pela extração de 6 fatores, equilibrando parcimônia e consistência teórica conforme indicado pela Análise Paralela.

Execução da análise fatorial e depuração das variáveis

Definido o número de fatores, estimou-se o modelo para os volantes pelo método MINRES, com rotação oblíqua (*oblimin*) e scores calculados por regressão. As variáveis com comunalidade inferior a 0,5 foram removidas, garantindo que apenas métricas com contribuição relevante à variância comum permanecessem no modelo final.

Reexecução e avaliação dos resultados

Após remover as variáveis com comunalidade inferior a 0,5, o KMO foi recalculado para as 74 métricas restantes, alcançando 0,906, valor classificado como “excelente”. O modelo com 6 fatores foi então reestimado utilizando o método MINRES, rotação *oblimin* e scores por regressão.

Tabela 12: Medidas de Ajuste do Modelo Fatorial com 6 fatores para Volantes

Indicador	Valor
RMSEA	0,174
RMSR	0,024
TLI	0,568
Fit (off-diagonal)	0,999
Variância Explicada	84,6%

A Tabela 12 resume as medidas de ajuste. Embora alguns índices globais, como RMSEA e TLI, apresentem valores mais conservadores, o modelo reproduz bem as correlações e explica 84,6% da variabilidade total, oferecendo uma representação consistente da estrutura dos volantes.

Interpretação e nomeação de cada fator

A análise das cargas fatoriais (Tabela 32) revelou seis dimensões bem definidas, com comunalidades altas indicando boa explicação da variabilidade das métricas.

O Fator 1 (33,8%) reúne métricas de passe, progressão e condução, sendo interpretado como **Construção e Distribuição**. O Fator 2 (14,8%) concentra ações defensivas, como desarmes, duelos e interceptações, representando **Combate Defensivo**. O Fator 3 (13,8%) agrupa indicadores ofensivos diretos, sendo nomeado **Ação Ofensiva Direta**. O Fator 4 (8,3%) destaca dribles e conduções agressivas, caracterizando **Condução Agres-**

siva. O Fator 5 (8,1%) envolve cruzamentos e bolas paradas, compondo **Cruzamentos e Bolas Paradas**. O Fator 6 (5,7%) reúne métricas de criação avançada, como assistências e passes decisivos, descrito como **Criação Avançada**.

Esses seis fatores sintetizam os principais domínios táticos que estruturam o desempenho dos volantes.

Cálculo dos scores

Para os volantes, os scores individuais foram obtidos a partir dos seis fatores extraídos e posteriormente normalizados para uma escala comum de 0 a 100. Em seguida, o Score Final foi calculado pela ponderação dos scores fatoriais pelas variâncias explicadas de cada fator, resultando em uma medida única e comparável de desempenho global.

Assim como no caso dos laterais, não foi necessário aplicar qualquer ajuste adicional ao indicador final.

Tabela 13: Top 5 Volantes.

Ranking	Jogador	Clube	Score Final
1	Gerson	Flamengo	64,4
2	Caio Alexandre	Bahia	63,1
3	Jean Lucas	Bahia	60,8
4	Gregore	Botafogo	60,2
5	Lucas Romero	Cruzeiro	57,9

A Tabela 13 apresenta os cinco volantes mais bem avaliados segundo o Score Final, destacando os atletas que exerceram maior influência técnica e tática ao longo da competição.

4.5.3 Clusterização pelo Método *K-means*

A Clusterização via *K-means* foi aplicada para verificar se o Score Final distingue níveis de desempenho entre os volantes. Essa análise examina se os atletas formam grupos coerentes a partir do indicador, reforçando sua utilidade na identificação de perfis distintos dentro da posição.

Definição do número de clusters

A definição do número de grupos para os volantes considerou diferentes critérios. O Método do Cotovelo (Figura 29) aponta queda acentuada até cerca de $k = 3$, enquanto o Método da Silhueta (Figura 30) também apresenta bom desempenho médio nesse valor. Embora a função `NbClust` apresente maior dispersão entre os índices, a solução com 3 clusters surge como alternativa consistente e interpretável.




Figura 29: Método do Cotovelo para definição do número de clusters dos Volantes.




Figura 30: Método da Silhueta para definição do número de clusters dos Volantes.

Diante desse conjunto de evidências, adotou-se a solução com 3 clusters, por equilibrar simplicidade, separação e coerência com os padrões de desempenho da posição.

Execução da clusterização

Com o número de grupos definido, aplicou-se o algoritmo *K-means* aos scores finais dos volantes. Após o particionamento, os clusters foram renumerados, definindo-se o grupo de maior desempenho como Cluster 1 e os demais em ordem decrescente, facilitando a interpretação dos perfis identificados.

Avaliação da clusterização

A qualidade da Clusterização dos volantes foi examinada a partir do índice de Silhueta e de testes estatísticos. O gráfico da Figura 31 apresenta silhuetas médias satisfatórias para os três grupos formados, indicando boa coesão interna e separação razoável entre os clusters.




Figura 31: Gráfico de Silhueta para $k = 3$ na clusterização dos Volantes.

Para avaliar se os grupos diferem significativamente em termos do Score Final, aplicou-se o teste de Kruskal–Wallis. A Tabela 14 mostra que as diferenças entre os clusters são altamente significativas, o que confirma a separação estatística entre os níveis de desempenho.

Tabela 14: Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Volantes.

H	p -valor	Decisão
127,39	$< 2.2 \times 10^{-16}$	Rejeita H_0

Diante da significância global, aplicou-se o teste de Dunn para comparações par-a-par. Conforme apresentado na Tabela 15, todas as comparações apresentaram diferenças significativas, reforçando a existência de três grupos bem distintos em termos de desempenho.

Tabela 15: Resultado do teste de Dunn para comparações entre os clusters dos Volantes.

Comparação	Z	p -valor	Decisão
1 – 2	3,825	$3,93 \times 10^{-4}$	Diferença significativa
1 – 3	10,158	$9,13 \times 10^{-24}$	Diferença significativa
2 – 3	8,071	$2,09 \times 10^{-15}$	Diferença significativa

Interpretação e perfil de cada cluster

A Figura 32 evidencia três grupos bem delimitados, com diferenças nítidas na distribuição do Score Final.



Figura 32: Distribuição do Score Final dos Volantes por cluster.

A seguir, sintetizam-se os perfis de cada grupo segundo os seis fatores identificados:

- **Cluster 1 — Volantes de Alto Impacto e Participação Ampla:** atletas completos, com forte atuação em construção, distribuição, combate e criação;
- **Cluster 2 — Volantes Equilibrados e de Contribuição Intermediária:** jogadores de desempenho consistente, com participação moderada nas ações defensivas, ofensivas e criativas;
- **Cluster 3 — Volantes de Baixa Participação e Menor Efetividade:** atletas pouco influentes na construção, defesa, criação e ações ofensivas.

4.5.4 Validação dos Resultados

O modelo destacou Gerson e Caio Alexandre como os melhores volantes (Tabela 13), enquanto nas seleções oficiais, Gerson e Marlon Freitas foram os escolhidos pelo GE (GE, 2024), e o Prêmio ESPN Bola de Prata destacou apenas Marlon Freitas (RESENDE, 2024). Apesar de diferenças pontuais, a presença recorrente desses atletas nas premiações e no modelo indica boa coerência externa, reforçando a capacidade do Score Final de representar o desempenho dos volantes.

4.6 Análise dos Meias

A avaliação dos meias abrangeu um total de 62 atletas. A maior parte deles é composta por jogadores brasileiros (46), acompanhados por representantes da Argentina, Uruguai, Paraguai, Colômbia, França, Nicarágua e Venezuela, o que evidencia uma presença internacional pontual, porém significativa. As idades variaram entre 16 e 42 anos, com média de 25,85 anos, revelando um grupo que combina jovens em desenvolvimento, atletas em fase de maturidade competitiva e jogadores mais experientes.

A base de dados utilizada para esta posição segue a mesma estrutura aplicada às demais posições de linha, reunindo 128 variáveis relacionadas ao desempenho dos atletas (Anexo A). Algumas dessas variáveis possuem caráter apenas descritivo e, por essa razão, foram excluídas da Análise Fatorial. Assim como observado nas análises de laterais e volantes, as variáveis (*Playing Time*) 90s e (*Team Success*) onGA não foram incorporadas a nenhuma etapa. Com isso, a análise fatorial dos meias foi conduzida exclusivamente com as variáveis de desempenho, totalizando 120 indicadores.

4.6.1 Preparação e Limpeza dos Dados

A preparação dos dados dos meias seguiu o protocolo da Seção 3.1.2, incluindo a incorporação das posições detalhadas do *Transfermarkt*. Foram unificados registros de atletas com mais de um clube, removidas variáveis descritivas, convertidas métricas para formato numérico e tratados valores ausentes. Em seguida, excluíram-se variáveis redundantes, sem variação, com combinações lineares (`findLinearCombos()`) ou correlação excessiva (`findCorrelation()`, *cutoff* = 0,99). Após a padronização em escala *z*, o conjunto final ficou composto por 56 variáveis.

4.6.2 Análise Fatorial

Avaliação da adequação dos dados

A adequação das variáveis dos meias foi verificada pelo índice KMO, mantendo-se apenas aquelas com valor individual acima de 0,5. Após a filtragem, o KMO global das 48 variáveis restantes foi de 0,785, classificado como “bom”, indicando qualidade suficiente da matriz de correlações para a extração fatorial. O teste de Shapiro–Wilk rejeitou a normalidade em todas as métricas, reforçando a necessidade de métodos adequados para dados não normais.

Definição do número de fatores

A definição da dimensionalidade para os meios foi guiada por diferentes critérios. Pelo *critério de Kaiser*, seriam retidos 5 fatores, mas o *scree plot* (Figura 33) indica uma estrutura mais simples, com forte queda inicial e rápida estabilização. A Análise Paralela (Figura 34) confirmou essa tendência ao apontar a retenção de apenas 2 fatores, únicos cujos autovalores superam os simulados.




Figura 33: *Scree plot* para Meias.




Figura 34: Análise Paralela para Meias.

Diante do conjunto das evidências, adotou-se a solução com 2 fatores, por equilibrar parcimônia e capacidade explicativa, em consonância com a indicação mais robusta fornecida pela Análise Paralela.

Execução da análise fatorial e depuração das variáveis

Com os fatores definidos, aplicou-se a Análise Fatorial pelo método MINRES, com rotação *oblimin* e scores obtidos por regressão. As variáveis com comunalidade inferior a 0,5 foram removidas, assegurando que apenas indicadores com contribuição relevante permanecessem no modelo final dos meias.

Reexecução e avaliação dos resultados

Após a remoção das variáveis com comunalidade inferior a 0,5, o conjunto final foi reduzido para 43 métricas. O KMO recalculado foi de 0,778, classificado como “bom”. Em seguida, a Análise Fatorial com 2 fatores foi novamente ajustada utilizando o método MINRES, rotação *oblimin* e scores estimados por regressão.

Tabela 16: Medidas de Ajuste do Modelo Fatorial com 2 fatores para Meias

Indicador	Valor
RMSEA	0,239
RMSR	0,055
TLI	0,444
Fit (off-diagonal)	0,994
Variância Explicada	79,1%

A Tabela 16 resume as medidas de ajuste. Apesar de RMSEA e TLI mais conservadores, o modelo apresenta resíduos baixos, boa reprodução das correlações e variância explicada de 79,1%, indicando que os dois fatores capturam de forma adequada os padrões de desempenho dos meias.

Interpretação e nomeação de cada fator

A análise das cargas fatoriais (Tabela 33) indica uma estrutura composta por dois fatores que explicam 79,1% da variância total, com comunalidades elevadas demonstrando boa representatividade das métricas.

O Fator 1 (48,1%) reúne métricas de finalizações, gols, cruzamentos, bolas paradas e ações criativas diretas, sendo interpretado como **Ação Ofensiva e Criação Direta**. O Fator 2 (31,0%) concentra indicadores de construção, progressão por passes, circulação de bola e apoio defensivo, caracterizando **Construção e Participação Tática**.

Esses dois fatores sintetizam o desempenho dos meias tanto na contribuição ofensiva direta quanto no papel organizacional e tático ao longo do jogo.

Cálculo dos scores

Para os meias, os scores individuais foram calculados a partir dos dois fatores extraídos e, em seguida, normalizados para uma escala comum de 0 a 100. O Score Final foi obtido pela combinação ponderada desses scores fatoriais, utilizando as variâncias explicadas como pesos, resultando em uma medida única de desempenho global.

Tabela 17: Top 5 Meias.

Ranking	Jogador	Clube	Score Final
1	Rodrigo Garro	Corinthians	91,5
2	Raphael Veiga	Palmeiras	85,9
3	Gustavo Scarpa	Atlético MG	77,7
4	Matheus Pereira	Cruzeiro	76,6
5	Franco Cristaldo	Grêmio	75,7

A Tabela 17 apresenta os cinco meias mais bem avaliados segundo o Score Final, evidenciando os atletas que tiveram maior impacto criativo e ofensivo ao longo da temporada.

4.6.3 Clusterização pelo Método *K-means*

Para avaliar se o Score Final distingue níveis de desempenho entre os meias, aplicou-se a Clusterização via *K-means*. Essa abordagem verifica se os atletas se organizam em grupos coerentes a partir do indicador, reforçando sua utilidade para identificar perfis distintos dentro da posição.

Definição do número de clusters

A definição do número de grupos para os meias foi guiada por diferentes critérios. O Método do Cotovelo (Figura 35) aponta queda acentuada da inércia até cerca de $k = 3$, enquanto o Método da Silhueta (Figura 36) indica valores médios mais altos em $k = 9$. Já a função `NbClust` sugere que a solução com 3 clusters é a mais consistente e interpretável.




Figura 35: Método do Cotovelo para definição do número de clusters dos Meias.




Figura 36: Método da Silhueta para definição do número de clusters dos Meias.

Diante dessas evidências, adotou-se a solução com 3 clusters, por oferecer melhor equilíbrio entre simplicidade, coerência e interpretabilidade dos padrões de desempenho dos meias.

Execução da clusterização

Com três grupos definidos, aplicou-se o algoritmo *K-means* aos scores finais dos meias. Após o particionamento, os clusters foram reorganizados em ordem decrescente de desempenho, definindo o grupo de maior score médio como Cluster 1, o que facilita a interpretação e comparação entre os níveis de performance identificados.

Avaliação da clusterização

A qualidade da Clusterização dos meios foi examinada por meio do índice de Silhueta e de testes estatísticos. O gráfico da Figura 37 apresenta valores médios de silhueta moderados nos três grupos formados, indicando coesão interna aceitável e separação razoável entre os clusters.




Figura 37: Gráfico de Silhueta para $k = 3$ na clusterização dos Meias.

Para verificar diferenças estatísticas entre os grupos, aplicou-se o teste de Kruskal–Wallis. Os resultados apresentados na Tabela 18 indicam que os clusters diferem significativamente em termos de Score Final, confirmando a separação entre os níveis de desempenho.

Tabela 18: Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Meias.

H	p -valor	Decisão
51,72	$5,876 \times 10^{-12}$	Rejeita H_0

Dada a significância global, realizou-se o teste de Dunn para comparações par-a-par. Conforme a Tabela 19, todas as comparações apresentaram diferenças significativas após ajuste, reforçando a existência de três grupos bem distintos entre si.

Tabela 19: Resultado do teste de Dunn para comparações entre os clusters dos Meias.

Comparação	Z	p -valor	Decisão
1 – 2	2,770	$1,68 \times 10^{-2}$	Diferença significativa
1 – 3	6,592	$1,30 \times 10^{-10}$	Diferença significativa
2 – 3	5,192	$6,24 \times 10^{-7}$	Diferença significativa

Interpretação e perfil de cada cluster

A Figura 38 mostra três grupos bem diferenciados quanto ao Score Final, com um cluster de alto desempenho, um intermediário e um de participação reduzida.



Figura 38: Distribuição do Score Final dos Meias por cluster.

A seguir são apresentados os perfis de cada cluster:

- **Cluster 1 — Meias de Alto Impacto Criativo e Ofensivo:** jogadores mais influentes, com forte criação ofensiva e participação ativa na organização do jogo;
- **Cluster 2 — Meias Equilibrados e de Contribuição Intermediária:** atletas de contribuição tática consistente, mas com menor protagonismo ofensivo;
- **Cluster 3 — Meias de Baixa Influência e Menor Efetividade:** grupo com pouca participação criativa e reduzido impacto tanto ofensivo quanto tático.

4.6.4 Validação dos Resultados

O ranking produzido pelo modelo indicou Rodrigo Garro como melhor meia na Tabela 17, resultado consistente com as seleções do GE e do Prêmio ESPN Bola de Prata, que também destacaram Garro e Alan Patrick (GE, 2024; RESENDE, 2024). A ESPN ainda incluiu Savarino devido ao esquema tático adotado.

Apesar dessas diferenças de formação entre as premiações, a recorrência dos mesmos nomes reforça a coerência externa do indicador, mostrando que o Score Final reflete adequadamente o desempenho real dos meias ao longo da competição.

4.7 Análise dos Pontas

A análise dos pontas considerou um total de 136 jogadores. A predominância é de atletas brasileiros (107), acompanhados por representantes de Argentina, Uruguai, Paraguai, Colômbia, Chile, Equador, Portugal, Costa Rica, República Democrática do Congo, Malásia, Nigéria e Venezuela, configurando uma posição com diversidade internacional mais ampla que as anteriores. As idades variam entre 15 e 36 anos, com média de 23,84 anos, indicando um grupo majoritariamente jovem, mas que também inclui atletas em fase intermediária de carreira e alguns jogadores mais experientes.

A base de dados utilizada segue a mesma estrutura aplicada às demais posições de linha, reunindo 128 variáveis (Anexo A). As variáveis de natureza exclusivamente descritiva foram removidas da Análise Fatorial, assim como ocorreu nas demais posições. Além disso, as variáveis (*Playing Time*) 90s e (*Team Success*) onGA não foram utilizadas em nenhuma etapa da análise. Assim, a construção dos fatores para os pontas foi realizada apenas com as variáveis efetivamente ligadas ao desempenho, totalizando 120 indicadores.

4.7.1 Preparação e Limpeza dos Dados

A preparação dos dados dos pontas seguiu o protocolo da Seção 3.1.2, incluindo a incorporação das posições detalhadas do *Transfermarkt*. Aplicou-se o fluxo padrão: consolidação de atletas que atuaram por mais de um clube, remoção de variáveis descritivas, conversão das métricas para formato numérico e tratamento de ausências. Também foram excluídas variáveis redundantes, sem variação ou com combinações lineares (`findLinearCombos()`). Após a padronização em escala z , o conjunto final foi composto por 92 variáveis para a Análise Fatorial.

4.7.2 Análise Fatorial

Avaliação da adequação dos dados

A adequação das variáveis dos pontas foi verificada pelo índice KMO, removendo-se aquelas com valor individual abaixo de 0,5. Após a filtragem, o KMO global das 86 variáveis restantes foi de 0,902, classificado como “excelente”. O teste de Shapiro–Wilk rejeitou a normalidade para todas as métricas, reforçando a necessidade de métodos adequados para dados não normais.

Definição do número de fatores

A definição da dimensionalidade integrou três critérios. Pelo *critério de Kaiser*, seriam retidos 10 fatores, enquanto o *scree plot* (Figura 39) mostra forte queda inicial seguida de estabilização, sugerindo múltiplas dimensões possíveis. Já a Análise Paralela (Figura 40) apontou solução mais parcimoniosa, indicando a retenção de 4 fatores.




Figura 39: *Scree plot* para Pontas.




Figura 40: Análise Paralela para Pontas.

Diante das evidências, adotou-se a solução com 4 fatores, que oferece maior parcimônia e melhor aderência à variabilidade observada, evitando a superestimação sugerida pelo critério de Kaiser.

Execução da análise fatorial e depuração das variáveis

Com os fatores definidos, aplicou-se a Análise Fatorial pelo método MINRES, com rotação *oblimin* e scores obtidos por regressão. As variáveis com comunalidade inferior a 0,5 foram excluídas, garantindo que apenas indicadores com contribuição relevante permanecessem no modelo final dos pontas.

Reexecução e avaliação dos resultados

Após remover as variáveis com comunalidade inferior a 0,5, o conjunto final passou a conter 75 métricas. O KMO recalculado foi de 0,924, classificado como “excelente”. Em seguida, a Análise Fatorial com 4 fatores foi reestimada pelo método MINRES, com rotação *oblimin* e scores obtidos por regressão.

Tabela 20: Medidas de Ajuste do Modelo Fatorial com 4 fatores para Pontas

Indicador	Valor
RMSEA	0,180
RMSR	0,028
TLI	0,544
Fit (off-diagonal)	0,998
Variância Explicada	84,4%

A Tabela 20 resume as principais medidas de ajuste. Apesar de RMSEA e TLI mais conservadores, o modelo apresenta resíduos baixos, excelente reprodução das correlações e elevada variância explicada (84,4%), indicando que os quatro fatores representam de forma consistente a estrutura dos pontas.

Interpretação e nomeação de cada fator

A análise fatorial dos pontas (Tabela 34) revelou quatro dimensões que explicam 84,4% da variância total.

O Fator 1 (35,0%) reúne métricas de passe, progressão, condução e ações defensivas, sendo interpretado como **Contribuição Geral ao Jogo**. O Fator 2 (19,4%) concentra dribles, conduções ofensivas e passes criativos, caracterizando **Criação Individual**. O Fator 3 (16,4%) agrupa gols, finalizações e presença no terço final, representando **Presença Ofensiva Direta**. O Fator 4 (13,6%) destaca cruzamentos e ações de bola

parada, compondo **Ações de Bola Parada e Cruzamentos**.

Esses quatro fatores sintetizam o desempenho dos pontas em termos de contribuição geral, criatividade, poder de finalização e eficiência nas bolas paradas.

Cálculo dos scores

Para os pontas, os scores individuais foram calculados a partir dos quatro fatores extraídos e posteriormente normalizados para uma escala comum de 0 a 100. O Score Final foi então construído por meio da ponderação dos scores fatoriais pelas respectivas variâncias explicadas.

Tabela 21: Top 5 Pontas Direita.

Ranking	Jogador	Clube	Score Final
1	Jhon Arias	Fluminense	71,5
2	Lucas Moura	São Paulo	66,9
3	Lucas Barbosa	Juventude	65,7
4	Estevão	Palmeiras	64,5
5	Luiz Henrique	Botafogo	63,6

Tabela 22: Top 5 Pontas Esquerda.

Ranking	Jogador	Clube	Score Final
1	Wesley	Internacional	70,3
2	Tomás Cuello	Athletico PR	65,7
3	Vitinho	RB Bragantino	64,6
4	Alejo Cruz	Atlético GO	56,9
5	Álvaro Barreal	Cruzeiro	55,8

A Tabela 21 e a Tabela 22 apresentam os dez pontas, cinco direita e cinco esquerda, mais bem avaliados segundo o Score Final, destacando os atletas com maior impacto ofensivo, criativo e desequilíbrio ao longo da temporada.

4.7.3 Clusterização pelo Método *K-means*

Para verificar se o Score Final diferencia os níveis de desempenho entre os pontas, aplicou-se a Clusterização via *K-means*. Essa análise permite observar se os atletas formam grupos coerentes a partir do indicador, servindo como uma validação adicional

da capacidade do score em identificar perfis distintos dentro da posição.

Definição do número de clusters

A definição do número de grupos para os pontas foi orientada por múltiplos critérios. O Método do Cotovelo (Figura 41) indica forte queda da inércia entre $k = 3$ e $k = 4$, enquanto o Método da Silhueta (Figura 42) apresenta valores elevados entre $k = 3$ e $k = 5$, com destaque para $k = 4$. A função `NbClust` também apontou maior consenso em torno de 4 clusters.




Figura 41: Método do Cotovelo para definição do número de clusters dos Pontas.




Figura 42: Método da Silhueta para definição do número de clusters dos Pontas.

Após comparar as soluções com 3 e 4 clusters, adotou-se a estrutura com 3 grupos, por oferecer o melhor equilíbrio entre coerência estatística e interpretabilidade para os pontas.

Execução da clusterização

Com o número de grupos definido, aplicou-se o algoritmo *K-means* aos scores finais dos pontas. Após o particionamento, os clusters foram reorganizados em ordem decrescente de desempenho, definindo o grupo de maior score médio como Cluster 1, o que facilita a leitura e a comparação dos perfis identificados.

Avaliação da clusterização

A qualidade da Clusterização dos pontas foi analisada por meio do índice de Silhueta e de testes estatísticos. A Figura 43 apresenta silhuetas médias elevadas para os três grupos formados, indicando boa coesão dentro dos clusters e separação consistente entre eles.




Figura 43: Gráfico de Silhueta para $k = 3$ na clusterização dos Pontas.

Para verificar diferenças significativas entre os grupos, aplicou-se o teste de Kruskal-Wallis. Os resultados da Tabela 23 mostram que os clusters apresentam distinções estatisticamente relevantes em termos de Score Final.

Tabela 23: Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Pontas.

H	<i>p</i> -valor	Decisão
106,91	$< 2.2 \times 10^{-16}$	Rejeita H_0

Dada a significância global, aplicou-se o teste de Dunn para avaliar comparações par-a-par. Conforme a Tabela 24, todas as combinações apresentaram diferenças significativas após ajuste, reforçando a existência de três grupos claramente distintos entre si.

Tabela 24: Resultado do teste de Dunn para comparações entre os clusters dos Pontas.

Comparação	Z	<i>p</i> -valor	Decisão
1 – 2	2,451	$4,27 \times 10^{-2}$	Diferença significativa
1 – 3	7,408	$3,84 \times 10^{-13}$	Diferença significativa
2 – 3	8,764	$5,66 \times 10^{-18}$	Diferença significativa

Interpretação e perfil de cada cluster

A Figura 44 mostra três grupos bem distintos em relação ao Score Final, distribuídos entre um cluster de alto desempenho, um intermediário e um de menor participação.




Figura 44: Distribuição do Score Final dos Pontas por cluster.

A seguir, sintetizam-se os perfis de cada grupo com base nos quatro fatores avaliados:

- **Cluster 1 — Pontas de Alto Impacto e Ação Completa:** jogadores mais completos, com alta contribuição geral, forte presença ofensiva, boa criação individual e participação sólida em bolas paradas e cruzamentos. Representam os jogadores mais influentes e decisivos da posição;
- **Cluster 2 — Pontas Intermediários e de Participação Moderada:** atletas de desempenho moderado e equilibrado, contribuindo de forma consistente, mas sem protagonismo ofensivo destacado;
- **Cluster 3 — Pontas de Baixa Influência e Menor Efetividade:** grupo com menor impacto geral, baixa criação, presença ofensiva limitada e pouca influência em ações de bola parada e cruzamentos.

4.7.4 Validação dos Resultados

A validação do modelo para os pontas foi realizada comparando o Score Final com as premiações oficiais. Embora o modelo identifique Jhon Arias e Wesley como líderes em suas respectivas faixas (Tabelas 21 e 22), as seleções do GE e da ESPN destacaram Estevão e Luiz Henrique (GE, 2024; RESENDE, 2024). Essa diferença ocorre porque as premiações adotaram um esquema tático que selecionou dois pontas direita, sem distinguir os lados do campo.

Mesmo assim, a presença recorrente de nomes bem avaliados pelo modelo, como Estevão e Luiz Henrique, confirma a consistência externa do indicador, mostrando que o Score Final reflete de forma coerente o desempenho dos pontas na temporada.

4.8 Análise dos Atacantes

A análise dos atacantes abrangeu 89 jogadores. A maior parte dos atletas é brasileira (61), acompanhada por representantes de Argentina, Uruguai, Paraguai, Chile, Colômbia, Dinamarca, Equador, Espanha, Itália, Países Baixos e Venezuela, evidenciando uma composição internacional relativamente variada dentro da posição. As idades registradas variaram de 15 a 39 anos, com média de 25,82 anos, indicando um grupo que reúne desde jovens promissores até atletas no auge competitivo e alguns jogadores mais veteranos.

O conjunto de dados utilizado para esta posição segue o mesmo padrão aplicado às demais categorias de jogadores de linha, totalizando 128 variáveis (Anexo A). As variáveis estritamente descritivas foram excluídas da Análise Fatorial, assim como nas análises anteriores. Da mesma forma, as variáveis (*Playing Time*) *90s* e (*Team Success*) *onGA* não foram consideradas em nenhuma etapa. Com isso, a construção dos fatores para os atacantes baseou-se exclusivamente nas variáveis efetivamente associadas ao desempenho, totalizando 120 indicadores.

4.8.1 Preparação e Limpeza dos Dados

A preparação dos dados dos atacantes seguiu o mesmo protocolo aplicado aos meias (Seção 4.6.1), incluindo a incorporação das posições do *Transfermarkt*. Aplicou-se o fluxo padrão: consolidação de atletas com mais de um clube, remoção de variáveis descritivas, conversão das métricas para formato numérico e tratamento de ausências. Em seguida, foram excluídas variáveis redundantes, sem variação, com combinações lineares (`findLinearCombos()`) ou correlação excessiva (`findCorrelation()`, *cutoff* = 0,99). Após a padronização em escala *z*, o conjunto final resultou em 80 variáveis para a Análise Fatorial.

4.8.2 Análise Fatorial

Avaliação da adequação dos dados

A adequação das variáveis dos atacantes foi avaliada pelo índice KMO, removendo-se aquelas com valor individual inferior a 0,5. Após a filtragem, as 72 variáveis restantes apresentaram KMO global de 0,848, classificado como “muito bom”. O teste de Shapiro–Wilk rejeitou a normalidade para todas as métricas, confirmando a necessidade de métodos

adequados para dados não normais.

Definição do número de fatores

A definição da dimensionalidade dos atacantes considerou três critérios. Pelo *critério de Kaiser*, seriam retidos 7 fatores, comportamento também visível no *scree plot* (Figura 45), que apresenta forte queda inicial seguida de longa estabilização. Já a Análise Paralela (Figura 46) indicou solução mais parcimoniosa, sugerindo a retenção de 4 fatores.




Figura 45: *Scree plot* para Atacantes.




Figura 46: Análise Paralela para Atacantes.

Diante das evidências, adotou-se a solução com 4 fatores, em consonância com a Análise Paralela, garantindo parcimônia e melhor robustez interpretativa para a modelagem fatorial.

Execução da análise fatorial e depuração das variáveis

Com os fatores definidos, aplicou-se a Análise Fatorial pelo método MINRES, com rotação *oblimin* e scores obtidos por regressão. As variáveis com comunalidade inferior a 0,5 foram excluídas, assegurando que apenas indicadores com contribuição relevante permanecessem no modelo final dos atacantes.

Reexecução e avaliação dos resultados

Após remover as variáveis com comunalidade abaixo de 0,5, o conjunto final passou a conter 67 métricas. O KMO recalculado foi de 0,852, classificado como “muito bom”. A Análise Fatorial com 4 fatores foi então reestimada pelo método MINRES, com rotação *oblimin* e scores gerados por regressão.

Tabela 25: Medidas de Ajuste do Modelo Fatorial com 4 fatores para Atacantes

Indicador	Valor
RMSEA	0,163
RMSR	0,037
TLI	0,528
Fit (off-diagonal)	0,997
Variância Explicada	80,2%

A Tabela 25 resume as medidas de ajuste. Embora RMSEA e TLI apresentem valores mais elevados, o modelo exhibe resíduos muito baixos, excelente reprodução das correlações e variância explicada de 80,2%, indicando que os quatro fatores capturam de forma consistente a estrutura dos atacantes.

Interpretação e nomeação de cada fator

A análise das cargas fatoriais dos atacantes (Tabela 35, no Apêndice) indica quatro fatores que, em conjunto, explicam 80,2% da variância total.

O primeiro fator (F1), com 41,0% da variância, representa **Produção Ofensiva Direta**, reunindo métricas de finalização, gols e participações decisivas. O segundo fator (F2), responsável por 18,2%, reflete **Ação Individual e Progressão**, associado a dribles e conduções. O terceiro fator (F3), com 11,1%, descreve **Ações de Bola Parada**, relacionado a cobranças ofensivas. Por fim, o quarto fator (F4), que explica 9,9%, sintetiza a

Participação Defensiva Complementar, reunindo indicadores de ajuda defensiva.

Esses quatro eixos resumem de forma clara os principais domínios que caracterizam o desempenho dos atacantes.

Cálculo dos scores

Para os atacantes, os scores individuais foram obtidos a partir dos quatro fatores extraídos e posteriormente transformados para uma escala comum de 0 a 100. Em seguida, o Score Final foi calculado pela combinação ponderada desses scores fatoriais, utilizando as variâncias explicadas de cada fator como pesos.

Tabela 26: Top 5 Atacantes.

Ranking	Jogador	Clube	Score Final
1	Hulk	Atlético MG	75,1
2	Luciano	São Paulo	70,3
3	Yuri Alberto	Corinthians	69,2
4	Alerrandro	Vitória	68,4
5	Janderson	Vitória	68,3

A Tabela 26 apresenta os cinco atacantes mais bem avaliados segundo o Score Final, destacando os atletas que exerceram maior influência ofensiva, criativa e tática ao longo da temporada.

4.8.3 Clusterização pelo Método *K-means*

Para avaliar se o Score Final distingue diferentes níveis de desempenho entre os atacantes, aplicou-se o algoritmo *K-means* aos scores obtidos. A análise verifica se os atletas se agrupam de forma coerente segundo seus padrões de atuação, funcionando como uma validação adicional da capacidade do indicador em identificar perfis distintos dentro da posição.

Definição do número de clusters

A definição do número adequado de grupos para os atacantes foi apoiada por diferentes critérios. O Método do Cotovelo (Figura 47) mostra uma queda acentuada da inércia até cerca de $k = 3$, enquanto o Método da Silhueta (Figura 48) apresenta valores

elevados nesse mesmo ponto, indicando boa separação entre os grupos.




Figura 47: Método do Cotovelo para definição do número de clusters dos Atacantes.




Figura 48: Método da Silhueta para definição do número de clusters dos Atacantes.

Os resultados do `NbClust` também convergiram para a solução com 3 grupos. Assim, considerando todas as evidências, adotou-se a estrutura com 3 clusters, que oferece o melhor equilíbrio entre coerência estatística e clareza interpretativa.

Execução da clusterização

Com o número de grupos definido, aplicou-se o algoritmo *K-means* aos scores finais dos atacantes. Após o particionamento, os clusters foram reorganizados em ordem

decrecente de desempenho, definindo-se o grupo com maior média como Cluster 1. Essa padronização facilita a leitura e a comparação entre os diferentes níveis de performance identificados.

Avaliação da clusterização

A qualidade da Clusterização dos atacantes foi examinada por meio do índice de Silhueta e de testes estatísticos. A Figura 49 apresenta valores médios de silhueta elevados nos três grupos formados, indicando boa coesão interna e separação consistente entre os clusters.




Figura 49: Gráfico de Silhueta para $k = 3$ na clusterização dos Atacantes.

Para verificar se os grupos diferem estatisticamente entre si, aplicou-se o teste de Kruskal–Wallis. Os resultados, apresentados na Tabela 27, mostram diferenças significativas no Score Final entre os clusters.

Tabela 27: Resultado do teste de Kruskal–Wallis para comparação dos clusters dos Atacantes.

H	p -valor	Decisão
74,43	$< 2.2 \times 10^{-16}$	Rejeita H_0

Diante da significância global, foi realizado o teste de Dunn. Conforme a Tabela 28, todas as combinações apresentaram diferenças estatisticamente significativas após ajuste, reforçando que os três clusters representam níveis distintos de desempenho.

Tabela 28: Resultado do teste de Dunn para comparações entre os clusters dos Atacantes.

Comparação	Z	p-valor	Decisão
1 – 2	4,593	$1,31 \times 10^{-5}$	Diferença significativa
1 – 3	8,580	$2,85 \times 10^{-17}$	Diferença significativa
2 – 3	5,332	$2,92 \times 10^{-7}$	Diferença significativa

Interpretação e perfil de cada cluster

A Figura 50 evidencia três grupos bem definidos em relação ao Score Final, distribuídos entre um cluster de maior desempenho, um intermediário e um de menor participação.




Figura 50: Distribuição do Score Final dos Atacantes por cluster.

A seguir, apresentam-se os perfis resumidos de cada cluster, considerando os quatro fatores analisados:

- **Cluster 1 — Atacantes de Alta Produção e Ação Completa:** atletas mais completos, com forte produção ofensiva, boa ação individual e participação relevante em bolas paradas e ações defensivas. Representam os jogadores mais determinantes do ataque;
- **Cluster 2 — Atacantes Intermediários e de Contribuição Equilibrada:** jogadores de contribuição equilibrada, com desempenho sólido, mas sem protagonismo;

- **Cluster 3 — Atacantes de Baixo Impacto Geral:** atletas com menor produção ofensiva, pouca participação defensiva e impacto reduzido em bolas paradas, representando o grupo menos efetivo.

4.8.4 Validação dos Resultados

A validação do modelo para os atacantes foi feita comparando o Score Final com as premiações da temporada. Embora GE e ESPN não tenham incluído um atacante em suas seleções (GE, 2024; RESENDE, 2024), o ranking do modelo (Tabela 26) destaca atletas de desempenho comprovado, como Hulk, Luciano e, especialmente, os artilheiros do campeonato Alerrandro e Yuri Alberto.

A presença desses nomes no Top 5 reforça a coerência externa do indicador e confirma que o Score Final representa adequadamente o desempenho dos atacantes na competição.

4.9 Seleção do Campeonato

A Figura 51 apresenta uma comparação direta entre a Seleção do Campeonato proposta por este estudo (à esquerda) e as seleções divulgadas pelo GE e pela ESPN (ao centro e à direita, respectivamente).

A seleção construída pelo modelo baseia-se exclusivamente no *Score Final*, refletindo o desempenho agregado de cada atleta ao longo da temporada. Já as seleções do GE (GE, 2024) e da ESPN (RESENDE, 2024) seguem critérios jornalísticos e táticos próprios, o que explica divergências pontuais, especialmente na escolha dos setores ofensivos.

Mesmo com diferenças estruturais entre os critérios, observa-se uma convergência importante: diversos jogadores bem avaliados pelo modelo também aparecem nas seleções oficiais, reforçando a coerência e validade prática do indicador desenvolvido.



Figura 51: Comparação entre a Seleção do Campeonato baseada no Score Final (esquerda), a Seleção do GE (centro) e a Seleção da ESPN (direita).

5 Conclusão

O presente estudo propôs um modelo estatístico robusto para avaliar o desempenho dos jogadores do Brasileirão a partir de suas funções táticas, combinando Análise Fatorial Exploratória, padronização de indicadores e construção de um Score Final unificado. A metodologia permitiu sintetizar dezenas de variáveis em fatores interpretáveis para cada posição, capturando dimensões essenciais do jogo, como criação, construção, contribuição defensiva, ações individuais e poder de finalização.

Os scores fatoriais normalizados possibilitaram comparar jogadores de maneira direta, resultando em rankings coerentes para todas as posições analisadas. A aplicação do algoritmo de Clusterização *K-means* reforçou a capacidade discriminativa do modelo, identificando grupos de desempenho bem definidos. A avaliação por silhueta, juntamente com os testes de Kruskal-Wallis e Dunn, confirmou que os clusters formados representam níveis distintos de performance, demonstrando validade estatística e consistência interna.

Adicionalmente, a comparação com as principais premiações do futebol brasileiro, como a Seleção do Campeonato divulgada pelo portal GE (GE, 2024) e a premiação Bola de Prata organizada pela ESPN (RESENDE, 2024), mostrou forte alinhamento entre os atletas mais bem avaliados pelo modelo e os nomes reconhecidos nacionalmente ao longo da temporada. Mesmo nos casos em que houve diferenças decorrentes de critérios subjetivos de votação, preferências táticas, impacto narrativo ao longo da temporada ou ainda diferenças entre métricas quantitativas e percepções qualitativas de especialistas, jogadores destacados pelo modelo frequentemente aparecem entre os melhores da competição, reforçando a validade externa da abordagem desenvolvida.

Em conjunto, os resultados indicam que o Score Final sintetiza de maneira fiel e interpretável o desempenho dos atletas em suas respectivas funções. A estrutura baseada em fatores, aliada à clusterização, oferece uma visão ampla, comparável e estatisticamente fundamentada do impacto de cada jogador ao longo do campeonato. Embora o estudo apresente limitações relacionadas à ausência de dados físicos e posicionais, o modelo se mostra uma ferramenta eficaz para análises de desempenho, podendo ser aplicada em contextos como avaliação interna de clubes e estudos comparativos entre temporadas.

6 Limitações e Trabalhos Futuros

Embora o presente trabalho busque oferecer uma avaliação abrangente do desempenho dos atletas por meio de técnicas de Análise Fatorial e Clusterização, algumas limitações devem ser reconhecidas.

Primeiramente, o modelo não incorpora variáveis relacionadas às condições físicas individuais dos jogadores, como desgaste, intensidade de minutos jogados, histórico de lesões ou parâmetros fisiológicos. Tais fatores influenciam diretamente o rendimento em campo e poderiam alterar substancialmente a interpretação dos resultados.

Além disso, não foram consideradas informações espaciais, como mapas de calor e padrões de movimentação. A ausência dessas métricas impede a avaliação do comportamento tático-posicional dos atletas ao longo das partidas. Esse ponto levanta um questionamento relevante: jogadores altamente obedientes às orientações táticas do treinador, permanecendo em zonas específicas do campo, podem ter sua contribuição subestimada quando avaliados exclusivamente por indicadores quantitativos agregados.

Outro ponto importante refere-se à definição da posição dos atletas. Neste estudo, cada jogador foi analisado apenas em sua posição de ofício conforme registrado no banco de dados, embora muitos deles atuem em diferentes funções ao longo da temporada. A versatilidade posicional, portanto, não foi capturada, podendo impactar tanto as métricas individuais quanto a comparação entre jogadores da mesma categoria.

Por fim, destaca-se que todas as análises se baseiam exclusivamente nos dados disponíveis na plataforma *FBref* (fbref.com) para a temporada considerada. A inclusão de fontes complementares, como métricas de rastreamento (*tracking data*), informações contextuais de jogo ou avaliações qualitativas, poderia ampliar a robustez das conclusões.

No que se refere a trabalhos futuros, ressalta-se que a Análise Fatorial empregada neste estudo possui caráter eminentemente exploratório, tendo como objetivo identificar estruturas latentes subjacentes ao conjunto de métricas analisadas, sem impor restrições prévias ao modelo. Como desdobramento natural, estudos subsequentes poderiam empregar a Análise Fatorial Confirmatória (AFC) para testar formalmente a estrutura fatorial identificada, avaliando a adequação do modelo por meio de índices de ajuste globais e permitindo a comparação entre modelos alternativos fundamentados teoricamente.

Adicionalmente, uma extensão metodológica relevante seria a reparametrização das cargas fatoriais de modo a eliminar cargas negativas antes do cálculo dos escores fatoriais. Embora cargas negativas sejam estatisticamente válidas no contexto exploratório,

sua presença pode dificultar a interpretação prática dos escores sintéticos, especialmente quando estes são utilizados para ordenação ou comparação direta de desempenho entre atletas. A imposição de cargas não negativas poderia facilitar a leitura dos fatores como dimensões monotônicas de desempenho.

Por fim, recomenda-se que análises futuras sejam conduzidas com base em métricas normalizadas pelo tempo de jogo, como indicadores por minuto ou por 90 minutos, em substituição às métricas em valores absolutos. O uso de taxas permitiria uma comparação mais equitativa entre atletas com diferentes volumes de participação, reduzindo o viés associado à minutagem acumulada e possibilitando a identificação de perfis de eficiência independentemente do tempo em campo.

Referências

BUSSAB, W. O.; MORETTIN, P. A. *Estatística Básica*. 5. ed. [S.l.]: Saraiva, 2003.

CHARRAD, M. et al. Nbclust: An r package for determining the relevant number of clusters in a data set. *Journal of Statistical Software*, v. 61, n. 6, 2014.

DUNN, O. J. Multiple comparisons among means. *Journal of the American Statistical Association*, v. 56, 1961.

GE, R. do. *Seleção do Brasileirão 2024*. 2024. Reportagem publicada em 08 dez. 2024. Disponível em: <https://ge.globo.com/futebol/brasileirao-serie-a/noticia/2024/12/08/selecao-do-brasileirao-2024-com-dominio-do-botafogo-veja-premiados.ghml>.

HAIR, J. F. et al. *Análise Multivariada de Dados*. [S.l.]: Bookman, 2009.

HARMAN, H. H. *Modern factor analysis*. 3. ed. [S.l.]: University of Chicago Press, 1976.

HORN, J. L. A rationale and test for the number of factors in factor analysis. *Psychometrika*, Springer, v. 30, n. 2, 1965.

JOHNSON, R. A.; WICHERN, D. W. *Applied Multivariate Statistical Analysis*. [S.l.]: Pearson, 2007.

KHASHAB, A. E. *LaLiga leads AI evolution with global outreach*. 2025. Reportagem publicada em 2 abr. 2025. Acesso em 9 nov. 2025. Disponível em: <https://www.reuters.com/sports/soccer/laliga-leads-ai-evolution-with-global-outreach-2025-04-02/>.

KRUSKAL, W. H.; WALLIS, W. A. Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, v. 47, n. 260, 1952.

LEWIS, M. *Moneyball: The Art of Winning an Unfair Game*. [S.l.]: W.W. Norton & Company, 2004.

MARDIA, K. V.; KENT, J. T.; BIBBY, J. M. *Multivariate Analysis*. [S.l.]: Academic Press, 1980.

RESENDE, I. *Premio ESPN Bola de Prata*. 2024. Reportagem publicada em 09 dez. 2024. Disponível em: https://www.espn.com.br/futebol/bola-de-prata/artigo/_/id/14545699/premio-espn-bola-de-prata-aposta-ganha-botafogo-domina-mas-estevao-faz-historia-e-leva-bola-de-c

RIBAS, A. *Além do scout: como a análise de dados cresce e influencia nos clubes do futebol brasileiro*. 2025. Reportagem publicada em 21 out. 2025. Disponível em: <https://ge.globo.com/mg/futebol/noticia/2025/10/21/alem-do-scout-como-a-analise-de-dados-cresce-e-influencia-nos-clubes-do-futebol-brasileiro.ghml>.

SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality (complete samples). *Biometrika*, v. 52, n. 3-4, 1965.

Apêndice

A Cargas Fatoriais, Comunalidades e Unidades para Goleiros

Tabela 29: Cargas Fatoriais (F1), Comunalidades (h^2) e Unidades (u^2) para Goleiros.

Variável	F1	h^2	u^2
(Performance) GA	0,961	0,924	0,076
(Performance) SoTA	0,992	0,985	0,015
(Performance) Saves	0,984	0,968	0,032
(Performance) CK	0,808	0,653	0,347
(Performance) CS	0,835	0,697	0,303
(Penalty Kicks) PKatt	0,730	0,534	0,466
(Expected) PSxG	0,981	0,962	0,038
(Launched) Cmp	0,964	0,929	0,071
(Launched) Att	0,973	0,946	0,054
(Passes) Att (GK)	0,947	0,897	0,103
(Passes) Thr	0,964	0,930	0,070
(Goal Kicks) Att	0,986	0,972	0,028
(Crosses) Opp	0,989	0,978	0,022
(Crosses) Stp	0,918	0,843	0,158

Notas: (i) F1 - Desempenho Global.

B Cargas Fatoriais, Comunalidades e Unidades para Zagueiros

Tabela 30: Cargas Fatoriais (F1–F4), Comunalidades (h^2) e Unidades (u^2) para Zagueiros.

Variável	F1	F2	F3	F4	h^2	u^2
(Performance) Gl	–	–	1,002	-0,166	0,837	0,163
(Performance) G-PK	–	–	0,956	-0,178	0,771	0,229
(Performance) CrdY	0,421	0,158	–	0,433	0,667	0,333
(Expected) xG	–	–	0,788	0,102	0,826	0,174
(Expected) npxG	–	–	0,767	0,133	0,832	0,168
(Expected) xAG	-0,174	0,748	–	0,318	0,602	0,398
(Progression) PrgC	0,508	0,506	–	-0,228	0,745	0,255
(Progression) PrgP	0,648	0,418	–	–	0,930	0,070
(Progression) PrgR	-0,121	0,885	–	–	0,675	0,325
(Standard) Sh	0,291	0,155	0,483	0,216	0,821	0,179
(Standard) SoT	0,250	–	0,647	0,105	0,760	0,240
(Total) Cmp	1,011	–	–	–	0,990	0,010
(Total) Att	0,950	–	–	–	0,996	0,004
(Total) TotDist	0,973	–	–	–	0,994	0,006
(Total) PrgDist	0,927	–	–	–	0,977	0,023
(Short) Cmp	1,025	–	–	–	0,944	0,056
(Short) Att	0,993	–	–	–	0,951	0,049
(Medium) Cmp	1,018	–	–	–	0,979	0,021
(Medium) Att	0,979	–	–	–	0,982	0,018
(Long) Cmp	0,737	0,114	–	0,138	0,877	0,123
(Long) Att	0,646	0,144	–	0,221	0,873	0,127
(Expected) xA	0,218	0,681	–	0,125	0,786	0,214
(Expected) KP	0,231	0,670	–	–	0,719	0,281
(Expected) 1/3	0,651	0,429	–	–	0,907	0,093
(Expected) PPA	–	0,802	–	–	0,692	0,308
(Pass Types) Live	0,969	–	–	–	0,995	0,005
(Pass Types) Dead	0,481	0,283	0,128	0,170	0,768	0,232
(Pass Types) FK	0,690	–	0,188	0,117	0,794	0,206
(Pass Types) Sw	0,454	0,186	–	0,183	0,518	0,482
(Pass Types) Crs	–	0,868	–	–	0,658	0,342
(Outcomes) Blocks	0,491	0,228	–	–	0,533	0,467
(SCA Types) PassLive	0,419	0,559	–	–	0,885	0,115
(SCA Types) Sh	-0,171	0,321	0,512	0,322	0,564	0,436
(Tackles) TklW	0,349	0,250	–	0,533	0,882	0,118
(Tackles) Def 3rd	0,413	0,142	–	0,553	0,883	0,117
(Tackles) Mid 3rd	0,408	0,186	–	0,373	0,693	0,307
(Challenges) Tkl	0,318	0,243	–	0,549	0,884	0,116
(Challenges) Att	0,289	0,269	–	0,571	0,895	0,105
(Blocks) Sh	0,427	–	0,344	0,412	0,857	0,143
(Blocks) Pass	0,241	0,183	0,147	0,545	0,794	0,206
(Blocks) Int	0,446	0,121	0,141	0,429	0,856	0,144
(Blocks) Ctr	0,513	–	0,236	0,381	0,911	0,089
(Touches) Touches	0,883	–	–	0,103	0,999	0,002
(Touches) Def Pen	0,753	–	0,178	0,229	0,925	0,075
(Touches) Def 3rd	0,893	–	0,100	0,152	0,982	0,018
(Touches) Mid 3rd	0,893	–	–	–	0,978	0,022
(Touches) Att 3rd	0,195	0,761	0,139	–	0,927	0,073
(Touches) Att Pen	0,402	0,163	0,408	0,168	0,839	0,161
(Take-Ons) Att	–	0,765	0,167	–	0,768	0,232
(Take-Ons) Succ	–	0,742	0,111	0,206	0,699	0,301
(Take-Ons) Tkld	–	0,686	0,274	–	0,609	0,391
(Carries) Carries	1,005	–	–	–	0,993	0,007
(Carries) TotDist	0,953	0,112	–	-0,101	0,970	0,030
(Carries) PrgDist	0,923	0,160	–	-0,129	0,946	0,054
(Carries) 1/3	0,434	0,628	–	-0,305	0,802	0,198
(Carries) Mis	0,249	0,432	0,157	0,219	0,702	0,298
(Carries) Dis	–	0,411	0,231	0,230	0,541	0,459
(Receiving) Rec	1,027	–	–	–	0,993	0,007
(Performance) Fls	0,417	–	–	0,437	0,699	0,301
(Performance) Fld	0,673	–	–	0,228	0,616	0,384
(Performance) Recov	0,614	0,203	0,111	0,220	0,931	0,069
(Aerial Duels) Won	0,510	–	0,255	0,385	0,862	0,138
(Aerial Duels) Lost	0,588	–	0,200	0,308	0,839	0,161

Notas: (i) F1 - Saída de Jogo, F2 - Construção e Ligação, F3 - Ação Ofensiva Direta e F4 - Duelos e Contenção; (ii) Cargas Fatoriais menores que 0,1, em módulo, foram omitidas da tabela para facilitar a interpretação.

C Cargas Fatoriais, Comunalidades e Unidades para Laterais

Tabela 31: Cargas Fatoriais (F1–F3), Comunalidades (h^2) e Unidades (u^2) para Laterais.

Variável	F1	F2	F3	h^2	u^2
(Performance) GlS	–	0,668	0,231	0,483	0,517
(Performance) Ast	0,142	0,430	0,373	0,543	0,457
(Performance) CrdY	0,611	0,116	–	0,502	0,498
(Expected) xG	–	0,769	0,125	0,698	0,302
(Expected) npxG	0,126	0,729	–	0,722	0,278
(Expected) xAG	0,531	0,235	0,263	0,720	0,280
(Progression) PrgC	0,693	0,329	–	0,880	0,120
(Progression) PrgP	1,017	–	–	0,929	0,071
(Progression) PrgR	0,485	0,460	–	0,795	0,205
(Standard) Sh	0,156	0,744	0,143	0,828	0,172
(Standard) SoT	–	0,712	0,144	0,639	0,361
(Total) Cmp	1,044	–	–	0,974	0,026
(Total) Att	0,994	–	–	0,989	0,011
(Total) TotDist	1,044	–	–	0,980	0,020
(Total) PrgDist	1,023	-0,129	0,102	0,961	0,039
(Short) Cmp	0,983	–	-0,110	0,919	0,081
(Short) Att	0,962	–	–	0,932	0,068
(Medium) Cmp	1,077	-0,143	–	0,963	0,037
(Medium) Att	1,035	–	–	0,974	0,026
(Long) Cmp	0,876	–	0,205	0,843	0,157
(Long) Att	0,795	–	0,282	0,860	0,140
(Expected) xA	0,557	0,230	0,304	0,802	0,198
(Expected) KP	0,662	0,125	0,354	0,902	0,098
(Expected) 1/3	1,040	-0,109	–	0,901	0,099
(Expected) PPA	0,721	0,100	0,193	0,789	0,211
(Expected) CrsPA	0,698	–	0,175	0,633	0,367
(Pass Types) Live	1,028	–	–	0,981	0,019
(Pass Types) Dead	0,772	0,137	0,202	0,941	0,059
(Pass Types) FK	0,795	-0,234	0,384	0,768	0,232
(Pass Types) Crs	0,408	0,311	0,490	0,909	0,091
(Pass Types) TI	0,790	0,207	–	0,904	0,096
(Pass Types) CK	–	–	0,909	0,885	0,115
(Corner Kicks) In	-0,129	–	0,910	0,779	0,221
(Corner Kicks) Out	0,195	–	0,758	0,734	0,266
(Outcomes) Blocks	0,543	0,301	0,283	0,857	0,143
(SCA Types) PassLive	0,813	0,129	–	0,906	0,094
(SCA Types) PassDead	0,317	–	0,781	0,894	0,106
(SCA Types) Sh	–	0,695	–	0,542	0,458
(GCA Types) PassLive	0,374	0,314	0,197	0,531	0,469
(GCA Types) PassDead	-0,112	–	0,805	0,595	0,405
(Tackles) TklW	0,760	0,226	–	0,829	0,171
(Tackles) Def 3rd	0,822	0,120	–	0,800	0,200
(Tackles) Mid 3rd	0,728	0,209	–	0,749	0,251
(Tackles) Att 3rd	0,441	0,376	0,110	0,640	0,360
(Challenges) Tkl	0,767	0,155	–	0,800	0,200
(Challenges) Att	0,777	0,126	–	0,796	0,204
(Blocks) Sh	0,675	0,149	–	0,579	0,421
(Blocks) Pass	0,560	0,338	0,133	0,793	0,207
(Blocks) Int	0,695	0,201	0,102	0,798	0,202
(Blocks) Clr	0,738	–	0,128	0,753	0,247
(Touches) Touches	0,950	–	–	0,995	0,005
(Touches) Def Pen	0,780	–	0,137	0,780	0,220
(Touches) Def 3rd	1,009	–	–	0,957	0,043
(Touches) Mid 3rd	1,054	–	–	0,982	0,018
(Touches) Att 3rd	0,604	0,385	0,130	0,947	0,053
(Touches) Att Pen	0,109	0,831	–	0,851	0,149
(Take-Ons) Att	0,396	0,603	-0,166	0,792	0,208
(Take-Ons) Succ	0,337	0,591	-0,137	0,694	0,306
(Take-Ons) Tkld	0,432	0,558	-0,164	0,772	0,228
(Carries) Carries	0,985	–	–	0,973	0,027
(Carries) TotDist	0,912	0,126	–	0,964	0,036
(Carries) PrgDist	0,937	–	–	0,956	0,044
(Carries) 1/3	0,710	0,293	–	0,869	0,131
(Carries) CPA	–	0,834	–	0,686	0,314
(Carries) Mis	0,510	0,482	-0,109	0,789	0,211
(Carries) Dis	0,533	0,476	-0,170	0,794	0,206
(Receiving) Rec	1,010	–	–	0,970	0,030
(Performance) Fls	0,673	0,204	–	0,671	0,329
(Performance) Fld	0,691	0,210	-0,214	0,638	0,362
(Performance) Recov	0,859	0,178	–	0,963	0,037
(Aerial Duels) Lost	0,517	0,327	–	0,669	0,331

Notas: (i) F1 - Contribuição Global e Progressão, F2 - Impacto Ofensivo Direto e F3 - Ações de Cruzamento e Bolas Paradas; (ii) Cargas Fatoriais menores que 0,1, em módulo, foram omitidas da tabela para facilitar a interpretação.

D Cargas Fatoriais, Comunalidades e Unidades para Volantes

Tabela 32: Cargas Fatoriais (F1–F6), Comunalidades (h^2) e Unidades (u^2) para Volantes.

Variável	F1	F2	F3	F4	F5	F6	h^2	u^2
(Performance) Gl	–	–	0,839	–	–	–	0,667	0,333
(Performance) Ast	–	0,270	0,171	–	–	0,593	0,695	0,305
(Performance) G-PK	–	–	0,852	–	–	–	0,659	0,341
(Performance) CrdY	0,147	0,626	–	0,127	–	–	0,635	0,365
(Expected) xG	–	–	0,958	–	–	–	0,887	0,113
(Expected) npG	–	–	0,993	–	–	–	0,912	0,088
(Expected) xAG	0,215	0,159	0,198	–	0,201	0,567	0,854	0,146
(Progression) PrgC	0,721	-0,229	0,120	0,341	–	0,153	0,888	0,112
(Progression) PrgP	0,754	0,134	–	–	–	0,275	0,971	0,029
(Progression) PrgR	–	–	0,439	0,335	0,116	0,315	0,863	0,137
(Standard) Sh	–	–	0,727	0,110	–	–	0,871	0,129
(Standard) SoT	–	–	0,803	–	–	–	0,853	0,147
(Total) Cmp	0,945	–	–	–	–	–	0,990	0,010
(Total) Att	0,890	–	–	–	–	–	0,994	0,006
(Total) TotDist	0,977	–	–	–	–	–	0,995	0,005
(Total) PrgDist	0,921	0,137	–	-0,103	–	–	0,977	0,023
(Short) Cmp	0,868	–	–	0,125	–	–	0,951	0,049
(Short) Att	0,830	–	–	0,119	–	–	0,956	0,044
(Medium) Cmp	0,997	–	–	–	–	–	0,984	0,016
(Medium) Att	0,957	–	–	–	–	–	0,987	0,013
(Long) Cmp	0,916	–	–	-0,122	–	0,111	0,899	0,101
(Long) Att	0,855	–	–	–	0,183	–	0,912	0,088
(Expected) xA	0,299	–	0,225	–	0,245	0,466	0,910	0,090
(Expected) KP	0,297	0,194	0,187	–	0,328	0,402	0,905	0,095
(Expected) 1/3	0,898	–	–	–	–	0,143	0,940	0,060
(Expected) PPA	0,350	–	0,189	–	0,211	0,465	0,855	0,145
(Expected) CrsPA	0,272	–	–	0,241	0,451	0,108	0,593	0,407
(Pass Types) Live	0,888	–	–	–	–	–	0,991	0,009
(Pass Types) Dead	0,752	–	–	–	0,442	–	0,843	0,157
(Pass Types) FK	0,943	–	-0,152	–	0,126	–	0,762	0,238
(Pass Types) Sw	0,654	–	–	0,106	–	–	0,570	0,430
(Pass Types) Crs	–	–	–	0,158	0,792	–	0,875	0,125
(Pass Types) CK	–	–	–	–	1,001	–	0,965	0,035
(Corner Kicks) In	–	–	–	–	0,976	-0,103	0,886	0,114
(Corner Kicks) Out	–	–	–	–	0,971	–	0,885	0,115
(Outcomes) Blocks	0,282	0,331	0,194	0,164	–	0,297	0,830	0,170
(SCA Types) PassLive	0,477	0,158	0,170	–	–	0,401	0,948	0,052
(SCA Types) PassDead	–	–	–	–	0,918	–	0,893	0,107
(SCA Types) TO	–	0,138	–	0,653	0,137	–	0,540	0,460
(SCA Types) Sh	–	0,119	0,568	0,156	–	–	0,531	0,469
(SCA Types) Fld	–	0,214	0,383	–	0,188	0,160	0,400	0,600
(GCA Types) PassLive	0,256	0,220	0,148	–	–	0,498	0,730	0,270
(Tackles) TklW	–	0,875	–	0,100	–	0,130	0,931	0,069
(Tackles) Def 3rd	–	0,832	–	0,149	–	–	0,837	0,163
(Tackles) Mid 3rd	0,103	0,809	–	0,123	–	–	0,884	0,116
(Tackles) Att 3rd	-0,156	0,560	–	0,304	–	0,195	0,524	0,476
(Challenges) Tkl	0,128	0,833	–	–	–	–	0,923	0,077
(Challenges) Att	0,169	0,706	–	0,148	–	–	0,878	0,122
(Blocks) Sh	0,237	0,590	0,234	-0,122	–	-0,179	0,741	0,259
(Blocks) Pass	0,161	0,515	0,267	0,184	–	–	0,806	0,194
(Blocks) Int	–	0,749	0,173	–	–	–	0,754	0,246
(Blocks) Clr	0,334	0,546	0,213	-0,144	–	-0,343	0,817	0,183
(Touches) Touches	0,786	0,177	–	–	–	–	0,996	0,004
(Touches) Def Pen	0,549	0,366	–	–	–	-0,416	0,787	0,213
(Touches) Def 3rd	0,760	0,309	–	–	–	-0,253	0,949	0,051
(Touches) Mid 3rd	0,841	0,162	–	–	–	–	0,980	0,020
(Touches) Att 3rd	0,374	–	0,314	0,216	0,167	0,286	0,956	0,044
(Touches) Att Pen	–	–	0,810	0,131	–	0,123	0,879	0,121
(Take-Ons) Att	–	0,142	0,111	0,810	–	–	0,968	0,032
(Take-Ons) Succ	–	0,192	–	0,799	–	–	0,862	0,138
(Take-Ons) Tkld	–	–	0,240	0,665	–	–	0,813	0,187
(Carries) Carries	0,917	–	–	–	–	–	0,993	0,007
(Carries) TotDist	0,950	–	–	0,182	–	–	0,976	0,024
(Carries) PrgDist	1,031	-0,151	–	0,140	–	–	0,956	0,044
(Carries) 1/3	0,702	-0,167	0,171	0,276	–	0,136	0,869	0,131
(Carries) CPA	0,109	-0,189	0,346	0,442	–	0,287	0,691	0,309
(Carries) Mis	0,154	0,314	0,311	0,363	–	–	0,837	0,163
(Carries) Dis	0,146	0,171	0,208	0,565	–	–	0,818	0,182
(Receiving) Rec	0,929	–	–	–	–	–	0,991	0,009
(Performance) Fls	0,266	0,550	0,142	0,153	–	–	0,838	0,162
(Performance) Fld	0,209	0,279	0,249	0,254	–	0,129	0,722	0,278
(Performance) Recov	0,417	0,434	–	0,222	–	–	0,928	0,072
(Aerial Duels) Won	0,186	0,492	0,447	-0,191	–	-0,213	0,733	0,267
(Aerial Duels) Lost	0,105	0,464	0,500	–	–	–	0,744	0,256

Notas: (i) F1 - Construção e Distribuição, F2 - Combate Defensivo, F3 - Ação Ofensiva Direta, F4 - Condução Agressiva, F5 - Cruzamentos e Bolas Paradas e F6 - Criação Avançada; (ii) Cargas Fatoriais menores que 0,1, em módulo, foram omitidas da tabela para facilitar a interpretação.

E Cargas Fatoriais, Comunalidades e Unicidade para Meias

Tabela 33: Cargas Fatoriais (F1–F2), Comunalidades (h^2) e Unicidade (u^2) para Meias.

Variável	F1	F2	h^2	u^2
(Performance) Gl	0,941	–	0,769	0,231
(Performance) Ast	0,433	0,459	0,680	0,320
(Performance) G-PK	0,818	–	0,651	0,349
(Performance) CrdY	–	0,660	0,526	0,474
(Expected) xG	0,987	-0,136	0,803	0,197
(Expected) npG	0,868	–	0,714	0,286
(Expected) xAG	0,833	0,141	0,880	0,120
(Progression) PrgC	0,445	0,488	0,743	0,257
(Progression) PrgP	0,367	0,648	0,893	0,107
(Progression) PrgR	0,560	0,424	0,829	0,171
(Standard) Sh	0,921	–	0,866	0,134
(Standard) SoT	0,861	–	0,840	0,161
(Standard) FK	0,932	-0,248	0,603	0,397
(Total) Cmp	0,314	0,713	0,924	0,076
(Total) PrgDist	0,440	0,606	0,938	0,062
(Short) Cmp	0,240	0,731	0,841	0,160
(Medium) Cmp	0,307	0,723	0,930	0,070
(Long) Cmp	0,681	0,313	0,864	0,136
(Long) Att	0,785	0,213	0,898	0,102
(Expected) xA	0,748	0,256	0,897	0,104
(Expected) KP	0,816	0,195	0,930	0,070
(Expected) 1/3	0,352	0,657	0,883	0,117
(Expected) PPA	0,519	0,463	0,824	0,176
(Expected) CrsPA	0,581	0,278	0,644	0,356
(Pass Types) Dead	0,800	0,190	0,892	0,108
(Pass Types) FK	0,628	0,294	0,743	0,257
(Pass Types) TB	0,418	0,437	0,626	0,374
(Pass Types) Sw	0,691	0,114	0,602	0,398
(Pass Types) Crs	0,927	–	0,908	0,092
(Pass Types) CK	0,934	–	0,907	0,093
(Corner Kicks) In	0,964	-0,166	0,730	0,270
(Corner Kicks) Out	0,903	–	0,796	0,204
(Outcomes) Blocks	0,373	0,625	0,860	0,140
(SCA Types) PassLive	0,595	0,429	0,900	0,100
(SCA Types) PassDead	0,938	–	0,845	0,155
(SCA Types) Sh	0,656	0,128	0,566	0,434
(GCA Types) PassLive	0,296	0,532	0,594	0,406
(Tackles) TklW	–	0,955	0,843	0,157
(Tackles) Def 3rd	-0,259	1,034	0,757	0,243
(Tackles) Mid 3rd	–	0,788	0,736	0,264
(Tackles) Att 3rd	–	0,720	0,585	0,415
(Challenges) Tkl	-0,107	1,002	0,863	0,137
(Challenges) Att	0,124	0,844	0,876	0,124

Notas: (i) F1 - Ação Ofensiva e Criação Direta e F2 - Construção e Participação Tática; (ii) Cargas Fatoriais menores que 0,1, em módulo, foram omitidas da tabela para facilitar a interpretação.

F Cargas Fatoriais, Comunalidades e Unidades para Pontas

Tabela 34: Cargas Fatoriais (F1–F4), Comunalidades (h^2) e Unidades (u^2) para Pontas.

Variável	F1	F2	F3	F4	h^2	u^2
(Performance) GlS	–	0,329	0,698	0,142	0,831	0,169
(Performance) Ast	–	0,319	0,310	0,355	0,548	0,452
(Performance) G-PK	–	0,285	0,732	0,127	0,831	0,169
(Performance) CrdY	0,546	-0,103	0,405	–	0,613	0,387
(Expected) xG	–	0,287	0,742	–	0,914	0,086
(Expected) npwG	–	0,246	0,782	–	0,917	0,083
(Expected) xAG	0,230	0,463	0,154	0,267	0,772	0,228
(Progression) PrgC	0,272	0,679	0,114	–	0,947	0,053
(Progression) PrgP	0,666	0,192	–	0,190	0,914	0,086
(Progression) PrgR	0,323	0,440	0,356	–	0,939	0,061
(Standard) Sh	0,198	0,218	0,642	0,130	0,945	0,055
(Standard) SoT	0,105	0,321	0,631	–	0,899	0,101
(Total) Cmp	0,696	0,177	–	0,200	0,952	0,048
(Total) Att	0,679	0,157	0,106	0,233	0,979	0,021
(Total) TotDist	0,685	0,148	–	0,254	0,965	0,035
(Total) PrgDist	0,745	–	–	0,320	0,960	0,040
(Short) Cmp	0,675	0,202	–	0,149	0,900	0,100
(Short) Att	0,666	0,198	0,129	0,143	0,924	0,076
(Medium) Cmp	0,738	0,171	–	0,197	0,950	0,050
(Medium) Att	0,727	0,159	–	0,221	0,966	0,034
(Long) Cmp	0,502	–	0,161	0,458	0,855	0,145
(Long) Att	0,475	–	–	0,581	0,923	0,077
(Expected) xA	0,376	0,411	0,104	0,274	0,863	0,137
(Expected) KP	0,356	0,382	0,105	0,356	0,898	0,102
(Expected) 1/3	0,687	–	–	0,256	0,842	0,158
(Expected) PPA	0,524	0,464	–	–	0,890	0,110
(Expected) CrsPA	0,642	0,223	-0,147	0,103	0,595	0,405
(Pass Types) Live	0,689	0,180	0,129	0,167	0,971	0,029
(Pass Types) Dead	0,411	–	-0,143	0,737	0,912	0,088
(Pass Types) FK	0,189	-0,125	–	0,875	0,882	0,118
(Pass Types) Crs	0,335	0,165	–	0,614	0,881	0,119
(Pass Types) TI	0,817	–	-0,397	0,120	0,575	0,425
(Pass Types) CK	–	–	–	1,015	0,942	0,058
(Corner Kicks) In	-0,178	–	–	0,977	0,816	0,184
(Corner Kicks) Out	–	–	–	0,885	0,771	0,229
(Outcomes) Blocks	0,604	0,233	0,156	0,127	0,876	0,124
(SCA Types) PassLive	0,457	0,405	0,180	0,142	0,927	0,073
(SCA Types) PassDead	–	–	–	0,962	0,886	0,114
(SCA Types) TO	–	0,840	0,144	-0,119	0,786	0,214
(SCA Types) Sh	0,121	0,135	0,573	0,196	0,672	0,328
(SCA Types) Fld	–	0,393	0,457	–	0,602	0,398
(GCA Types) PassLive	0,105	0,382	0,304	0,239	0,639	0,361
(GCA Types) TO	-0,240	0,593	0,296	–	0,490	0,510
(Tackles) TklW	0,784	0,152	0,114	-0,116	0,798	0,202
(Tackles) Def 3rd	0,894	0,162	-0,117	-0,100	0,768	0,232
(Tackles) Mid 3rd	0,822	–	0,159	-0,106	0,782	0,218
(Tackles) Att 3rd	0,426	0,116	0,358	–	0,551	0,449
(Challenges) Tkl	0,852	–	–	–	0,779	0,221
(Challenges) Att	0,713	0,132	0,162	–	0,802	0,198
(Blocks) Pass	0,670	–	0,292	–	0,757	0,243
(Blocks) Int	0,690	–	–	0,169	0,741	0,259
(Blocks) Clr	0,716	-0,268	0,365	0,115	0,779	0,221
(Touches) Touches	0,639	0,206	0,179	0,177	0,992	0,008
(Touches) Def Pen	0,742	-0,183	0,326	–	0,774	0,226
(Touches) Def 3rd	0,927	–	–	0,105	0,926	0,074
(Touches) Mid 3rd	0,709	–	0,172	0,173	0,959	0,041
(Touches) Att 3rd	0,437	0,370	0,241	0,186	0,974	0,026
(Touches) Att Pen	0,126	0,487	0,530	–	0,953	0,047
(Take-Ons) Att	0,203	0,847	–	–	0,967	0,033
(Take-Ons) Succ	0,191	0,866	–	–	0,929	0,071
(Take-Ons) Tkld	0,222	0,792	–	–	0,926	0,074
(Carries) Carries	0,577	0,315	0,165	0,146	0,982	0,018
(Carries) TotDist	0,426	0,555	0,110	–	0,973	0,027
(Carries) PrgDist	0,384	0,605	–	0,118	0,967	0,033
(Carries) 1/3	0,379	0,539	–	0,145	0,908	0,092
(Carries) CPA	-0,134	0,830	0,237	–	0,868	0,132
(Carries) Mis	0,367	0,352	0,411	–	0,878	0,122
(Carries) Dis	0,367	0,552	0,196	–	0,846	0,154
(Receiving) Rec	0,602	0,253	0,198	0,139	0,971	0,029
(Performance) Fls	0,540	–	0,487	–	0,821	0,179
(Performance) Fld	0,313	0,340	0,306	–	0,720	0,280
(Performance) Off	–	0,130	0,685	–	0,559	0,441
(Performance) Recov	0,554	0,308	0,224	–	0,945	0,055
(Aerial Duels) Won	0,462	-0,283	0,732	-0,173	0,747	0,253
(Aerial Duels) Lost	0,428	-0,141	0,731	-0,116	0,836	0,164

Notas: (i) F1 - Contribuição Geral, F2 - Criação Individual, F3 - Presença Ofensiva e F4 - Bola Parada e Cruzamentos;
(ii) Cargas Fatoriais menores que 0,1, em módulo, foram omitidas da tabela para facilitar a interpretação.

G Cargas Fatoriais, Comunalidades e Unidades para Atacantes

Tabela 35: Cargas Fatoriais (F1–F4), Comunalidades (h^2) e Unidades (u^2) para Atacantes.

Variável	F1	F2	F3	F4	h^2	u^2
(Performance) GlS	0,913	–	–	–	0,825	0,175
(Performance) Ast	0,831	–	0,143	–	0,694	0,306
(Performance) G-PK	0,896	–	–	–	0,818	0,182
(Performance) PKatt	0,710	-0,117	0,315	-0,165	0,550	0,450
(Performance) CrdY	0,634	–	–	0,287	0,673	0,327
(Expected) xG	1,038	–	–	-0,117	0,915	0,085
(Expected) npxG	1,004	–	-0,125	–	0,876	0,124
(Expected) xAG	0,786	0,118	–	–	0,807	0,193
(Progression) PrgC	0,249	0,777	–	–	0,883	0,117
(Progression) PrgP	0,613	0,110	0,204	0,326	0,917	0,083
(Progression) PrgR	0,662	0,407	–	–	0,935	0,065
(Standard) Sh	0,920	–	–	–	0,949	0,051
(Standard) SoT	0,925	–	–	–	0,915	0,085
(Standard) FK	–	–	0,899	-0,115	0,830	0,170
(Total) PrgDist	0,491	0,169	0,237	0,430	0,959	0,041
(Short) Cmp	0,573	0,271	0,101	0,275	0,930	0,070
(Medium) Cmp	0,542	–	0,231	0,478	0,927	0,073
(Medium) Att	0,624	–	0,170	0,433	0,957	0,043
(Long) Cmp	0,456	-0,117	0,406	0,514	0,872	0,128
(Long) Att	0,484	–	0,434	0,398	0,897	0,103
(Expected) xA	0,592	0,248	0,150	0,135	0,812	0,188
(Expected) KP	0,820	0,131	–	–	0,885	0,115
(Expected) 1/3	0,554	–	0,208	0,463	0,873	0,127
(Expected) PPA	0,627	0,227	0,208	–	0,810	0,190
(Pass Types) Dead	0,764	–	0,227	–	0,690	0,310
(Pass Types) FK	–	–	0,875	0,307	0,920	0,080
(Pass Types) TB	0,569	–	0,275	–	0,510	0,490
(Pass Types) Sw	0,515	-0,194	0,459	0,297	0,687	0,313
(Pass Types) Crs	0,346	0,409	0,131	–	0,550	0,450
(Pass Types) TI	0,183	0,382	0,321	0,227	0,628	0,372
(Pass Types) CK	–	0,173	0,837	-0,124	0,738	0,262
(Corner Kicks) Out	-0,108	0,167	0,908	-0,201	0,853	0,147
(Outcomes) Blocks	0,563	0,342	–	0,199	0,831	0,169
(SCA Types) PassLive	0,760	0,195	–	–	0,880	0,120
(SCA Types) PassDead	–	0,102	0,866	-0,112	0,811	0,189
(SCA Types) TO	–	0,839	–	–	0,740	0,260
(SCA Types) Sh	0,732	–	0,168	–	0,755	0,245
(SCA Types) Fld	0,484	0,243	0,356	-0,156	0,639	0,361
(GCA Types) PassLive	0,817	–	0,104	–	0,733	0,267
(GCA Types) Sh	0,443	–	0,450	–	0,553	0,447
(Tackles) TklW	0,133	0,505	-0,169	0,497	0,787	0,213
(Tackles) Def 3rd	-0,163	0,553	-0,189	0,633	0,738	0,262
(Tackles) Mid 3rd	0,224	0,448	-0,128	0,430	0,739	0,261
(Challenges) Tkl	–	0,542	-0,142	0,507	0,780	0,221
(Challenges) Att	0,454	0,320	-0,148	0,389	0,832	0,168
(Blocks) Sh	0,473	–	–	0,442	0,546	0,454
(Blocks) Pass	0,463	0,346	-0,177	0,304	0,769	0,231
(Blocks) Int	–	0,479	-0,188	0,474	0,677	0,323
(Blocks) Clr	0,825	–	-0,188	–	0,727	0,273
(Touches) Def Pen	0,746	–	-0,168	0,183	0,742	0,258
(Touches) Def 3rd	0,361	0,284	–	0,570	0,931	0,070
(Touches) Mid 3rd	0,685	0,124	–	0,318	0,966	0,034
(Touches) Att 3rd	0,705	0,317	–	–	0,982	0,018
(Touches) Att Pen	0,983	0,116	-0,150	-0,110	0,973	0,027
(Take-Ons) Att	–	0,841	0,211	–	0,922	0,078
(Take-Ons) Succ	–	0,836	0,233	–	0,889	0,111
(Take-Ons) Tkld	0,186	0,741	0,178	-0,126	0,808	0,192
(Carries) TotDist	0,306	0,588	0,134	0,224	0,958	0,042
(Carries) PrgDist	0,176	0,716	0,132	0,154	0,910	0,090
(Carries) 1/3	0,103	0,752	0,134	0,125	0,846	0,154
(Carries) CPA	0,306	0,734	–	-0,331	0,840	0,160
(Carries) Mis	0,754	0,331	–	-0,116	0,877	0,123
(Carries) Dis	0,492	0,451	0,151	–	0,802	0,198
(Performance) 2CrdY	–	-0,124	0,695	0,284	0,532	0,468
(Performance) Fls	0,703	0,219	-0,124	–	0,733	0,267
(Performance) Fld	0,706	0,157	0,175	–	0,798	0,202
(Performance) Off	0,911	–	-0,159	-0,201	0,629	0,371

Notas: (i) F1 - Produção Ofensiva, F2 - Ação Individual e Progressão, F3 - Bola Parada e F4 - Participação Defensiva;
(ii) Cargas Fatoriais menores que 0,1, em módulo, foram omitidas da tabela para facilitar a interpretação.

Anexo

A Variáveis dos Jogadores de Linha

1. *Player*: Nome;
2. *Nation*: Nacionalidade;
3. *Position*: Posição;
4. *Squad*: Clube;
5. *Age*: Idade;
6. *Born*: Ano de nascimento;
7. *(Playing Time) 90s*: Minutos jogados dividido por 90;
8. *(Performance) Gls*: Gols marcados;
9. *(Performance) Ast*: Assistências realizadas;
10. *(Performance) G+A*: Gols mais assistências;
11. *(Performance) G-PK*: Gols marcados, excluindo pênaltis;
12. *(Performance) PK*: Gols de pênalti;
13. *(Performance) PKatt*: Pênaltis cobrados;
14. *(Performance) CrdY*: Cartões amarelos recebidos;
15. *(Performance) CrdR*: Cartões vermelhos recebidos;
16. *(Expected) xG*: Gols esperados;
17. *(Expected) npxG*: Gols esperados sem considerar pênaltis;
18. *(Expected) xAG*: Gols esperados assistidos;
19. *(Expected) npxG+xAG*: Gols esperados sem considerar pênaltis mais gols esperados assistidos;
20. *(Progression) PrgC*: Condução progressiva ofensiva;
21. *(Progression) PrgP*: Passes progressivos ofensivos;
22. *(Progression) PrgR*: Passes progressivos ofensivos recebidos;
23. *(Standard) Sh*: Chutes realizados;
24. *(Standard) SoT*: Chutes no alvo realizados;

25. *(Standard) SoT%*: Percentual de chutes no alvo realizados;
26. *(Standard) G/Sh*: Gols por chutes realizados;
27. *(Standard) G/SoT*: Gols por chutes no alvo realizados;
28. *(Standard) Dist*: Distância média dos chutes;
29. *(Standard) FK*: Chutes em cobranças de falta;
30. *(Expected) np $\times$ G/Sh*: Gols esperados sem considerar pênaltis por chutes realizados;
31. *(Expected) G- $\times$ G*: Gols marcados menos gols esperados;
32. *(Expected) np:G- $\times$ G*: Gols marcados, excluindo pênaltis menos gols esperados sem considerar pênaltis;
33. *(Total) Cmp*: Passes completados;
34. *(Total) Att*: Passes tentados;
35. *(Total) Cmp%*: Percentual de passes completados;
36. *(Total) TotDist*: Distância total percorrida pelos passes;
37. *(Total) PrgDist*: Distância progressiva percorrida pelos passes;
38. *(Short) Cmp*: Passes curtos completados;
39. *(Short) Att*: Passes curtos tentados;
40. *(Short) Cmp%*: Percentual de passes curtos completados;
41. *(Medium) Cmp*: Passes médios completados;
42. *(Medium) Att*: Passes médios tentados;
43. *(Medium) Cmp%*: Percentual de passes médios completados;
44. *(Long) Cmp*: Passes longos completados;
45. *(Long) Att*: Passes longos tentados;
46. *(Long) Cmp%*: Percentual de passes longos completados;
47. *(Expected) $\times$ A*: Assistências esperadas;
48. *(Expected) A- $\times$ AG*: Assistências realizadas menos gols esperados assistidos;
49. *(Expected) KP*: Passes que resultaram diretamente em um chute;
50. *(Expected) 1/3*: Passes realizados no terço final ofensivo;
51. *(Expected) PPA*: Passes para a área adversária;
52. *(Expected) CrsPA*: Cruzamentos para a área adversária;

- 53. (*Pass Types*) *Live*: Passes com bola em jogo;
- 54. (*Pass Types*) *Dead*: Passes com bola parada;
- 55. (*Pass Types*) *FK*: Passes tentados em cobranças de falta;
- 56. (*Pass Types*) *TB*: Passes entre as costas dos defensores adversários;
- 57. (*Pass Types*) *Sw*: Inversões de jogo;
- 58. (*Pass Types*) *Crs*: Cruzamentos realizados;
- 59. (*Pass Types*) *TI*: Laterais cobrados;
- 60. (*Pass Types*) *CK*: Escanteios cobrados;
- 61. (*Corner Kicks*) *In*: Escanteios fechados cobrados;
- 62. (*Corner Kicks*) *Out*: Escanteios abertos cobrados;
- 63. (*Corner Kicks*) *Str*: Escanteios retos cobrados;
- 64. (*Outcomes*) *Cmp*: Passes completados;
- 65. (*Outcomes*) *Off*: Passes impedidos;
- 66. (*Outcomes*) *Blocks*: Passes bloqueados;
- 67. (*SCA*) *SCA*: Ações criadoras de chute;
- 68. (*SCA Types*) *PassLive*: Ações criadoras de chute originadas de passes com bola em jogo;
- 69. (*SCA Types*) *PassDead*: Ações criadoras de chute originadas de passes com bola parada;
- 70. (*SCA Types*) *TO*: Ações criadoras de chute após drible;
- 71. (*SCA Types*) *Sh*: Ações criadoras de chute a partir de outro chute;
- 72. (*SCA Types*) *Fld*: Ações criadoras de chute após falta sofrida;
- 73. (*SCA Types*) *Def*: Ações criadoras de chute após ação defensiva;
- 74. (*GCA*) *GCA*: Ações criadoras de gol;
- 75. (*GCA Types*) *PassLive*: Ações criadoras de gol originadas de passes com bola em jogo;
- 76. (*GCA Types*) *PassDead*: Ações criadoras de gol originadas de passes com bola parada;
- 77. (*GCA Types*) *TO*: Ações criadoras de gol após drible;
- 78. (*GCA Types*) *Sh*: Ações criadoras de gol a partir de outro chute;

-
79. (*GCA Types*) *Fld*: Ações criadoras de gol após falta sofrida;
 80. (*GCA Types*) *Def*: Ações criadoras de gol após ação defensiva;
 81. (*Tackles*) *Tkl*: Desarmes realizados;
 82. (*Tackles*) *TklW*: Desarmes vencidos;
 83. (*Tackles*) *Def 3rd*: Desarmes realizados no terço defensivo;
 84. (*Tackles*) *Mid 3rd*: Desarmes realizados no meio-campo;
 85. (*Tackles*) *Att 3rd*: Desarmes realizados no terço ofensivo;
 86. (*Challenges*) *Tkl*: Duelos defensivos vencidos;
 87. (*Challenges*) *Att*: Duelos defensivos tentados;
 88. (*Challenges*) *Tkl%*: Percentual de duelos defensivos vencidos;
 89. (*Challenges*) *Lost*: Duelos defensivos perdidos;
 90. (*Blocks*) *Blocks*: Bloqueios totais;
 91. (*Blocks*) *Sh*: Chutes bloqueados;
 92. (*Blocks*) *Pass*: Passes bloqueados;
 93. (*Blocks*) *Int*: Interceptações;
 94. (*Blocks*) *Tkl+Int*: Desarmes realizados mais interceptações;
 95. (*Blocks*) *Clr*: Cortes realizados;
 96. (*Blocks*) *Err*: Erros defensivos que resultaram em finalização adversária;
 97. (*Touches*) *Touches*: Total de toques na bola;
 98. (*Touches*) *Def Pen*: Toques na área defensiva;
 99. (*Touches*) *Def 3rd*: Toques no terço defensivo;
 100. (*Touches*) *Mid 3rd*: Toques no meio-campo;
 101. (*Touches*) *Att 3rd*: Toques no terço ofensivo;
 102. (*Touches*) *Att Pen*: Toques na área adversária;
 103. (*Touches*) *Live*: Toques com bola em jogo;
 104. (*Take-Ons*) *Att*: Dribles tentados;
 105. (*Take-Ons*) *Succ*: Dribles bem-sucedidos;
 106. (*Take-Ons*) *Succ%*: Percentual de dribles bem-sucedidos;
 107. (*Take-Ons*) *Tkld*: Dribles em que o jogador foi desarmado;

- 108. (*Take-Ons*) *Tkld%*: Percentual de dribles em que o jogador foi desarmado;
- 109. (*Carries*) *Carries*: Conduções de bola realizadas;
- 110. (*Carries*) *TotDist*: Distância total conduzida com a bola;
- 111. (*Carries*) *PrgDist*: Distância progressiva conduzida com a bola;
- 112. (*Carries*) *1/3*: Conduções que avançaram ao terço final ofensivo;
- 113. (*Carries*) *CPA*: Conduções que entraram na área adversária;
- 114. (*Carries*) *Mis*: Domínios errados;
- 115. (*Carries*) *Dis*: Perdas de posse;
- 116. (*Receiving*) *Rec*: Passes recebidos;
- 117. (*Team Success*) *onGA*: Gols sofridos pelo time com o jogador em campo;
- 118. (*Performance*) *2CrdY*: Segundo cartão amarelo;
- 119. (*Performance*) *Fls*: Faltas cometidas;
- 120. (*Performance*) *Fld*: Faltas sofridas;
- 121. (*Performance*) *Off*: Impedimentos;
- 122. (*Performance*) *PKwon*: Pênaltis sofridos;
- 123. (*Performance*) *PKcon*: Pênaltis cometidos;
- 124. (*Performance*) *OG*: Gols contra;
- 125. (*Performance*) *Recov*: Bolas recuperadas;
- 126. (*Aerial Duels*) *Won*: Duelos aéreos vencidos;
- 127. (*Aerial Duels*) *Lost*: Duelos aéreos perdidos;
- 128. (*Aerial Duels*) *Won%*: Percentual de duelos aéreos vencidos.

Fonte: adaptado de *FBref* (fbref.com).

B Variáveis dos Goleiros

1. *Player*: Nome;
2. *Nation*: Nacionalidade;
3. *Pos*: Posição;
4. *Squad*: Clube;
5. *Age*: Idade;
6. *(Playing Time) 90s*: Minutos jogados dividido por 90;
7. *(Performance) GA*: Gols sofridos;
8. *(Performance) SoTA*: Chutes no alvo sofridos;
9. *(Performance) Saves*: Defesas realizadas;
10. *(Performance) Save%*: Percentual de defesas realizadas;
11. *(Performance) FK*: Gols sofridos em cobranças de falta;
12. *(Performance) CK*: Gols sofridos em escanteios;
13. *(Performance) OG*: Gols contra sofridos;
14. *(Performance) CS*: Partidas sem sofrer gols;
15. *(Performance) CS%*: Percentual de partidas sem sofrer gols;
16. *(Penalty Kicks) PKatt*: Pênaltis enfrentados;
17. *(Penalty Kicks) PKA*: Pênaltis convertidos pelo adversário;
18. *(Penalty Kicks) PKsv*: Pênaltis defendidos;
19. *(Penalty Kicks) PKm*: Pênaltis desperdiçados pelo adversário;
20. *(Penalty Kicks) Save%*: Percentual de pênaltis defendidos;
21. *(Expected) PSxG*: Gols esperados pós-chute;
22. *(Expected) PSxG/SoT*: Gols esperados pós-chute dividido por chutes no alvo sofridos;
23. *(Expected) PSxG +/-*: Diferença entre gols esperados pós-chute e os gols sofridos;
24. *(Launched) Cmp*: Lançamentos certos;
25. *(Launched) Att*: Lançamentos tentados;
26. *(Launched) Cmp%*: Percentual de lançamentos certos;

27. *(Passes) Att (GK)*: Passes tentados (geral);
28. *(Passes) Thr*: Passes arremessados com as mãos;
29. *(Passes) Launch%*: Percentual de passes longos lançados;
30. *(Passes) AvgLen*: Distância média dos passes;
31. *(Goal Kicks) Att*: Tiros de meta executados;
32. *(Goal Kicks) Launch%*: Percentual de tiros de meta longos;
33. *(Goal Kicks) AvgLen*: Distância média dos tiros de meta;
34. *(Crosses) Opp*: Cruzamentos oponentes enfrentados;
35. *(Crosses) Stp*: Cruzamentos interceptados;
36. *(Crosses) Stp%*: Percentual de cruzamentos interceptados;
37. *(Sweeper) #OPA*: Ações defensivas fora da área;
38. *(Sweeper) AvdDist*: Distância média das ações fora da área;
39. *(Performance) CrdY*: Cartões amarelos recebidos;
40. *(Performance) 2CrdY*: Segundo cartão amarelo recebido;
41. *(Performance) CrdR*: Cartões vermelhos recebidos;
42. *(Team Success) onGA*: Gols sofridos pelo time com o jogador em campo.

Fonte: adaptado de *FBref* (fbref.com).